

分类号_____

密级_____

U D C_____

编号_____

山西转型综合改革示范区管委会
博士后科研工作站
博 士 后 研 究 工 作 报 告

题目：基于机器视觉的刀具缺陷识别研究
Title: Research on Tool Defect Recognition Based on
Machine Vision

博士后姓名： 王振华

合作导师： 黄庆学 霍锋锋

企业名称： 智奇铁路设备有限公司

流动站名称： 太原理工大学

进站日期： 2022年6月9日

工作完成日期： 2022年6月-2026年8月

报告提交日期： 2026年8月

摘要

刀具是现代机床加工最重要的工具之一，在现代制造业中，车削加工是机械加工的重要组成部分，而车刀作为切削工具，其质量直接关系到加工精度和效率。圆形机夹式车刀因其灵活性和高效性更是被广泛应用于各种金属切削作业中。为了确保产品的加工质量，对刀具缺陷的及时防控至关重要。尽管深度学习方法已被广泛应用于表面缺陷检测，但由于圆形机夹式车刀的样式多样、表面轮廓复杂以及缺陷位置、面积、形状多变等问题，这些常规模型往往难以实现高准确率的缺陷检测。因此，本文先使用单任务深度学习模型完成车刀缺陷分类任务，再使用多任务学习模型完成对圆形机夹式车刀刀刃缺陷的分割任务，主要研究内容和工作如下：

(1) 针对刀具类型不一、轮廓复杂等问题，使用 Xception 预训练模型进行分类时，若直接使用未处理的圆形车刀图片作为输入，其刀具表面轮廓复杂，对缺陷特征进行提取时容易受到噪声干扰。因此，本文在图像处理时提出了一种提取刀刃轮廓的方法，并且在特征提取时通过多尺度融合提高对小目标缺陷的检测精度。首先在图像处理时，使用图像增强、二值化处理、连通域处理以及形态学处理等方法将圆形机夹式车刀的刀刃轮廓边缘分离出来作为模型输入，减少刀具表面噪声的干扰；其次，将 Xception 深层次与低层次的特征进行融合，同时引入 CBAM 注意力模块构建改进的分类模型 X-CBAM，提高特征提取能力，进而提升模型分类准确率。实验结果表明，本文方法与原检测方法相比，图像处理后的准确率提高 3.44%，通过多尺度融合以及 CBAM 注意力模块的处理后准确率进一步提高了 3.45%，mPA 值能够达到 0.9494。

(2) 针对单任务分割模型不能有效分割圆形机夹式车刀刀刃缺陷的问题，提出了一种结合分类与分割的多任务学习模型 Multi-UF-Xception，主要是通过对 U-Net 模型进行改进提升分割精度。首先，使用 Xception 特征提取部分替代原 U-Net 模型编码器部分，提升编码器部分的特征提取能力；其次，分割与分类两任务共享 Xception 网络，形成两个任务分支；然后，分割任务融合 FPN 架构提升多尺度信息的整合能力，在横向连接处加入改进后的 AGs 注意力机制过滤冗余信息并增强对重要特征的提取能力；之后，分类任务处也将深层次与低层次信息融合并引入 CBAM 注意力模块提高特征提取能力；最后，通过损失函数权重调整，进一步提升模型的分割精度。实验结果表明，单任务分割模型的分割精度 MIoU 值只有 0.6062，而使用本文提出的多任务学习模型 Multi-UF-Xception，并经过损失权重调整，最后的分割精度 MIoU 值能够达到 0.8626。

(3) 结合所提出的分类与分割算法，同时考虑到生产实践中对刀具缺陷检测的实际需求，搭建了圆形机夹式车刀刀刃缺陷检测平台。首先，用户可通过输

入账户与密码登录该平台；然后，在模型训练界面上可以实现常规模型对刀具缺陷数据集的训练，并展示训练过程与结果；最后，在图像检测界面对本文的两个模型算法进行调用，可以实现对车刀合格与不合格的分类以及对刀刃缺陷的分割提取，为机加工生产提供一定参考作用。

关键词：缺陷检测；Xception 网络模型；多任务学习；U-Net 模型；注意力机制

ABSTRACT

The cutting tool is one of the most important tools for modern machine tool processing, and in the modern manufacturing industry, turning is an important part of machining, and the quality of turning tools as cutting tools is directly related to machining accuracy and efficiency. Due to its flexibility and efficiency, round clamp turning tools are widely used in various metal cutting operations. In order to ensure the processing quality of the product, it is essential to prevent and control tool defects in a timely manner. Although traditional deep learning methods have been widely used in surface defect detection, these conventional models are often difficult to achieve high-accuracy defect detection due to the various styles of circular machine clamp turning tools, complex surface contours, and variable defect locations, areas, and shapes. Therefore, in this thesis, a single-task deep learning model is used to complete the classification task of turning tool defects, and then a multi-task learning model is used to complete the segmentation task of the cutting edge defects of circular machine clamp turning tools. The main research contents and work are as follows:

(1) When using the Xception pre-trained model for classification, if the unprocessed circular turning tool image is directly used as the input, the surface profile of the tool is complex, and it is easy to be disturbed by noise when extracting defect features. In order to solve this problem, this thesis proposes a method to extract the edge profile in image processing, and improves the detection accuracy of small target defects through multi-scale fusion in feature extraction. Firstly, in image processing, image enhancement, binarization processing, connected domain processing and morphological processing are used to separate the edge of the cutting edge of the circular clamp-type turning tool as the model input to reduce the interference of the surface noise of the tool. Secondly, the deep-level and low-level features of Xception were fused, and the CBAM attention module was introduced to construct an improved classification model X-CBAM, which improved the feature extraction ability and improved the classification accuracy of the model. Experimental results show that compared with the original detection method, the accuracy of the proposed method after image processing is increased by 3.44%, and the accuracy of the proposed method is further improved by 3.45% after processing through multi-scale fusion and CBAM attention module, and the mPA value can reach 0.9494.

(2) In order to solve the problem that the single-task segmentation model cannot effectively divide the blade defects of circular machine clamp turning tools, a multi-

task learning model combining classification and segmentation was proposed, which mainly improved the segmentation accuracy by improving the U-Net model. Firstly, the Xception feature extraction part was used to replace the encoder part of the original U-Net model to improve the feature extraction ability of the encoder part. Secondly, the two tasks of segmentation and classification share the Xception network to form two task branches. Then, the segmentation task fusion FPN architecture improves the integration ability of multi-scale information, and the improved AGs attention mechanism is added to the horizontal connection to filter redundant information and enhance the extraction ability of important features. Later, the classification task department also fused deep and low-level information and introduced the CBAM attention module to improve the feature extraction ability. Finally, the weight adjustment of the loss function is used to further improve the segmentation accuracy of the model. Experimental results show that the MIoU value of the single-task segmentation model is only 0.6062, while the multi-task learning model Multi-UF-Xception proposed in this thesis can reach 0.8626 after adjusting the loss weight.

(3) Combined with the proposed classification and segmentation algorithms, and considering the actual needs of tool defect detection in production practice, a circular clip-on turning tool edge defect detection platform was built. First, users can log in to the platform by entering their account and password. Then, on the model training interface, the conventional model can be trained on the tool defect dataset, and the training process and results can be displayed. Finally, the two model algorithms in this thesis are called in the image detection interface, which can realize the classification of qualified and unqualified turning tools and the segmentation and extraction of cutting edge defects, which provides a certain reference for machining production.

Keywords: defect detection; Xception network model; Multi-task learning; U-Net model; attention mechanis.

目 录

摘 要.....	I
ABSTRACT.....	III
目 录.....	V
图目录.....	VIII
表目录.....	X
1. 绪论.....	11
1.1 研究背景及意义.....	11
1.2 国内外研究现状	12
1.2.1 基于传统机器学习的缺陷检测方法.....	12
1.2.2 基于深度学习的缺陷检测方法.....	13
1.2.3 刀具缺陷检测研究.....	15
1.3 研究内容及技术路线	16
1.3.1 研究内容.....	16
1.3.2 技术路线.....	17
1.4 报告章节安排	18
2. 刀具缺陷检测基本原理.....	19
2.1 图像处理方法	19
2.1.1 图像增强处理.....	19
2.1.2 二值化处理.....	20
2.1.3 形态学处理.....	20
2.2 深度学习基础理论	21
2.2.1 卷积神经网络基础理论.....	21
2.2.2 特征提取算法.....	24
2.2.3 注意力机制.....	25
2.2.4 多任务学习.....	25
2.3 刀具图像数据集采集	27
2.3.1 刀具类型.....	27
2.3.2 图像采集.....	27
2.4 本章小结	29

3. 基于改进 XCEPTION 模型的圆形刀具缺陷分类方法研究.....	30
3.1 改进的 X-CBAM 分类模型网络设计	30
3.1.1 Xception 模型介绍	30
3.1.2 CBAM 注意力模块	32
3.1.3 改进模型 X-CBAM 整体网络结构	34
3.2 数据预处理	35
3.2.1 数据划分	35
3.2.2 刀刃轮廓提取	36
3.3 实验结果与分析	38
3.3.1 实验环境设置	38
3.3.2 实验评价指标	39
3.3.3 实验结果对比与分析	40
3.4 本章小结	46
4. 基于多任务学习的刀具缺陷分.....	48
4.1 多任务网络模型 MULTI-UF-XCEPTION 设计	48
4.1.1 改进 U-Net 网络描述	48
4.1.2 FPN 结构描述	50
4.1.3 Attention Gates (AGs) 注意门机制.....	52
4.1.4 Multi-UF-Xception 整体网络结构.....	53
4.1.5 损失函数	54
4.2 实验	55
4.2.1 数据处理	55
4.2.2 实验环境设置	55
4.2.3 实验评价标准	56
4.2.4 实验结果与分析	56
4.3 本章小结	60
5. 刀具缺陷检测平台设计	62
5.1 平台功能概述	62
5.2 平台架构及设计	62
5.3 平台实现及操作	63
5.3.1 登录与注册界面	63
5.3.2 模型训练界面	64

5.3.3 图像检测界面66

5.4 本章小结68

6. 总结与展望.....69

6.1 研究总结69

6.2 研究展望70

参考文献.....71

致 谢.....77

博士后期间取得的成果.....78

图目录

图 1-1 刀刃常见缺陷	11
图 1-2 技术路线	17
图 2-1 不同方法下的灰度直方图	19
图 2-2 形态学处理过程	21
图 2-3 卷积操作图	22
图 2-4 池化操作图	23
图 2-5 硬参数共享	26
图 2-6 软参数共享	27
图 2-7 圆形机夹式车刀类型	27
图 2-8 形状测量激光显微镜系统	28
图 2-9 图像拍摄过程	28
图 3-1 Xception 网络结构图	31
图 3-2 深度可分离卷积过程	32
图 3-3 残差结构	32
图 3-4 CBAM 注意力模块	33
图 3-5 通道注意力模块	33
图 3-6 空间注意力模块	34
图 3-7 改进 Xception 整体网络结构	35
图 3-8 不同方法进行图像增强所得结果	36
图 3-9 不同二值化处理方法所得结果	37
图 3-10 连通域阈值消除花纹轮廓的处理过程	37
图 3-11 刀刃轮廓修复处理过程	38
图 3-12 各层加入 CBAM 注意力模块前后的特征图对比	41
图 3-13 混淆矩阵图	41
图 3-14 预测结果	42
图 3-15 训练集和测试集的准确率	43
图 3-16 训练集和测试集的损失率	43
图 3-17 不同模型训练后的 P-R 曲线	44
图 3-18 不同模型训练后计算所得 AP 值与 mPA 值	44
图 3-19 不同模型的准确率曲线图	45
图 3-20 不同模型的损失率曲线图	45
图 3-21 刀具图像在不同模型下的预测结果	46

图 4-1 U-Net 网络结构图	49
图 4-2 改进 U-Net 网络结构图	50
图 4-3 FPN 网络结构图	51
图 4-4 AGs 模块网络结构图	52
图 4-5 Multi-UF-Xception 模型网结构图	54
图 4-6 掩码标签制作	55
图 4-7 通道特征图可视化结果对比	57
图 4-8 单任务分割与多任务分割的损失率曲线对比	58
图 4-9 不同模型的 IoU 值对比	59
图 4-10 消融实验中模型对刀刃缺陷进行分割预测的结果对比	60
图 5-1 平台架构图	63
图 5-2 登录与注册界面	64
图 5-3 模型训练界面	65
图 5-4 图像导入	66
图 5-5 模型训练结果	66
图 5-6 图像检测界面	67
图 5-7 分类检测	67
图 5-8 分割检测	68

表目录

表 2-1 形状测量激光显微镜系统相关参数	28
表 3-1 Xception 特征提取网络部分模型参数	35
表 3-2 不同处理方式对比结果	41
表 3-3 刀具图像在不同图像处理方式下的预测概率	42
表 3-4 不同模型之间的准确率与损失率结果对比	45
表 3-5 刀具图像在不同模型下的预测概率	46
表 4-1 基于单任务模型 XU-Net 的消融实验结果对比	57
表 4-2 分类任务消融实验结果对比	58
表 4-3 权重调整前后结果对比	59

1. 绪论

1.1 研究背景及意义

高速发展的工业系统需要更加适应匹配的产品，同时需要在生产过程中对产品质量做更好地监控与控制^[1-3]。如果产品表面出现划痕、斑点或孔洞等缺陷，很大程度上会对其性能造成不利影响，还会降低产品的美观性和使用舒适度^[4-7]。在现代制造领域，机械加工技术成为影响产品质量的主要因素，特别是在金属切削加工中，精度和效率是两大关键要素^[8]，所以对车刀等切削刀具的质量要求也越来越高。例如在汽车发动机的曲轴制造中，零部件的尺寸精度需要控制在极小的范围内，这就要求车刀能够稳定地进行精确切削。




图 1-1 刀刃常见缺陷

Fig. 1-1 Common blade defects

在机械加工刀具中，圆形机夹式车刀是一种常用的刀具类型，被广泛应用于各类车床上，完成对各种回转体零件的加工，如轴类、盘类零件等，由于其独特的结构形式，包括圆形的刀体和可更换的刀片，使得它在批量生产中具有安装方便、换刀快捷等优点。但是，在实际应用中刀刃经常出现磨损、剥落、崩刃、塑性变形等缺陷，如图 1-1 所示，这会影响加工质量和效率，因此需要对刀具缺陷进行定期检测。以往可以通过人工目测的传统方法检测缺陷，但是该方法存在漏检、误检、效率低、工人疲劳等众多问题^[9-12]。因此，对于自动化、智能化的刀具缺陷检测需求也越来越高，通过机器视觉方法对刀具缺陷进行快速精准的识别^[13]，及时判断刀具是否能够满足加工要求，对于保证产品质量具有重要意义。

由于对象以及环境的不同，缺陷检测方法的研究也在不断改变，传统方法中主要通过各种基于信号的方法检测缺陷，比如电磁信号^[14]、声波信号^[15]，但是这些方法操作复杂、准确率低、成本高。随着人工智能的快速发展和现代科技的不

断进步，机器学习成为可以模拟人类大脑进行学习的一种有效方法，进而代替人工进行数据分析以及图像识别，各种基于机器学习的模型被逐渐研发出来，这使得机器视觉技术在缺陷检测方面得到更为广泛的应用^[16]。

与传统的缺陷检测方法相比，机器学习主要是通过建立的数据标签以及网络模型自动对图像进行特征学习，完成分类、分割等任务。机器学习方法包括传统机器学习方法以及深度学习方法，其中深度学习方法具有更为强大的学习能力，卷积神经网络（Convolutional Neural Network, CNN）模型具有更为广泛的应用能力。针对刀具缺陷检测问题，基于深度学习的机器视觉技术首先通过高清相机获取高质量的刀具缺陷图片，然后使用计算机技术对图像进行预处理，最后将预处理后的刀具缺陷数据集带入深度学习模型进行训练^[17]，通过深度学习方法对刀具缺陷特征进行判断和识别，既可以实现对刀具缺陷的高精度检测，又具有高效率、节省人力物力的优点。

本文针对刀具表面轮廓复杂影响刀刃缺陷的判断、刀具刀刃缺陷位置形态差异大等刀具刀刃缺陷检测过程中存在的问题，提出了一种结合图像处理与深度学习的圆形机夹式车刀刃缺陷检测方法，通过图像处理技术去除噪声，之后通过深度学习模型进行训练分析，实现圆形机夹式车刀刃缺陷的快速检测，以提高检测效率与精度，进一步保证产品的加工质量。

1.2 国内外研究现状

多年来，刀具缺陷检测主要是通过人工目测，而基于传统机器学习和深度学习的缺陷检测方式是近年来的主要研究方向。大多数深度学习模型需要大量的数据样本和复杂的数据形式才能够在训练之后实现高精度的识别与检测，而随着国内外学者对深度学习的深入研究，深度学习模型对于小样本数据集也能够达到较好的检测效果^[18-20]，一系列基于深度学习的检测算法也逐步应用到刀具缺陷识别领域，从而实现刀具缺陷的机器视觉智能化检测。

1.2.1 基于传统机器学习的缺陷检测方法

国内外学者对缺陷检测已经进行了深入研究，传统方法中的间接测量法主要是通过传感器等装置检测缺陷产生的物理特征变化^[21]，而随着机器视觉技术的发展，传统的间接测量法也逐渐被基于机器学习的直接测量法所替代，机器视觉检测成为提高缺陷检测效率的有效方法。Guan 等^[22]提出了一种基于高斯金字塔分解的显著性图构建的带钢缺陷图像检测算法，该方法通过高斯金字塔法和中心-环绕差分运算对图像进行分解与融合，实现对带钢缺陷的完整分割和准确检测。武汉大学的舒文娉等^[23]通过支持向量机（SVM）对印品缺陷的特征数据进行训练和测试，最终达到缺陷识别率 100%、分类准确率 93.94%的效果。Tao 等^[24]为了检测大口径光学元件上的弱划痕缺陷，提出了一种基于 GIST 特征的分类方法，

该方法可以正确检测与划分出复杂图像中多种类型的弱划痕。彭道刚等^[25]提出了基于改进二维最大类间方差法（OTSU）和区域生长法的电厂高温管道缺陷定位与分割方法，能够更加精确地对复杂背景下的电厂管道缺陷进行检测与分割。湖南大学的周显恩等^[26]提出一种基于随机圆评估定位方法的瓶口缺陷检测技术，该方法结合了残差分析、动态阈值分割以及全局阈值分割。通过这种方法，他们成功地将瓶口缺陷检测的正确率提升了 2.22%。Song 等^[27]提出了一种基于局部完全二值模式的热轧带钢表面缺陷噪声鲁棒方法，该方法通过构建一个围绕邻居的相邻评估窗口来修改完整局部二值模式的阈值，能够在不同环境下保持较好的缺陷识别准确性。Ding 等^[28]提出了一种基于定向梯度直方图（HOG）的织物缺陷检测方法，该方法首先对图像的每个块级特征进行 HOG 编码，然后利用 AdaBoost 特征选择算法自动筛选出一小部分具有代表性的 HOG 特征，以提高检测的鲁棒性，最后，通过支持向量机（SVM）对织物缺陷进行分类，实现了高效的缺陷检测。Tsai 等^[29]提出了一种不同于传统矩形结构元形态学算法的弧形 se 形态学运算方法，可以有效地强化圆形刀具加工表面的局部缺陷以及去除刀痕背景，对各种细小缺陷检测能够达到较高的检测精度。

1.2.2 基于深度学习的缺陷检测方法

传统的机器视觉检测方法依赖于手工设计的特征提取和手工制作的分类器或回归模型来处理图像数据^[30]，这些方法能够达到较好的检测效果，但是存在一定局限性，比如不能覆盖不同类型的缺陷、不能适应不同环境下的缺陷检测等问题。作为机器学习的分支，深度学习通过卷积网络模型可以提取复杂图像中的一些区别性特征，提高了缺陷检测的效率和准确率。目前，单任务学习是深度学习中最常见的形式，模型专注于解决一个特定的任务，如图像分类或物体检测，尽管这种方法在许多应用场景中表现良好，但在面对数据稀缺和复杂场景时，其局限性便显现出来，难以有效适应。相比之下，多任务学习允许模型同时解决多个相关任务^[31]。

（1）单任务学习

单任务学习主要方法包括分类、分割以及目标检测，分类作为最基本的检测手段，能够更快地反映出目标的整体信息，国内外学者在缺陷的分类检测上做了大量研究。Liu 等^[32]针对深度卷积神经网络模型在小数据集上容易出现过拟合的问题，提出了一种改进的 VGG-16 网络深度模型，不仅能够适应大型数据集，也能够适应小型数据集。Shobha 等^[33]通过九层深度卷积神经网络模型对钢表面缺陷进行分类，最终模型的准确率达 93.27%。Imoto 等^[34]利用基于卷积神经网络模型的迁移学习算法进行半导体制造的缺陷分类检测，与手动检查相比，该方法劳动力减少了 2/3。Neuhauser 等^[35]提出了一种基于数据增强和迁移学习的铝表面缺陷分类检测方法，在仅包含 813 张图像的数据集上进行训练时，分类精度为 0.98。

Wei 等^[36]提出了一种基于 Faster R-CNN 的多尺度缺陷检测网络,能够更好解决铝型材表面缺陷分类和定位的问题,该方法通过对 10 类表面缺陷进行训练和评估,最后的综合平均精度 mPA 达到 75.8%。Li 等^[37]针对卷积神经网络模型全局表示能力不足的问题,将卷积神经网络与 Transformer 编码器进行融合构建 CNN-T 模型,实验表明,该模型能够更加准确地对带钢表面缺陷进行分类。Ferreira 等^[38]提出一种多模型卷积神经网络融合方法,通过对不同的预训练模型进行训练后再融合在一起,以提高对金属表面缺陷的分类精度。

为了更精准的定位以及表现出特征区域,一般会通过分割或目标检测的方法进行缺陷检测。王一等^[39]在 U-Net 网络中同时加入多尺度自适应形态特征提取模块(MAFE)模块与瓶颈注意力模块(BAM)模块,增强了模型的特征提取能力,提升了对金属工件表面的缺陷分割能力。He 等^[40]提出了一种针对钢板缺陷检测与分类的方法,该方法利用多层特征融合网络(MFN)整合多层级的特征为单一特征表示,随后,采用区域建议网络(RPN)生成感兴趣区域(ROI),以此实现对缺陷的精确分类与定位,这种方法通过结合多层次的信息,提高了检测和分类的准确性。李原等^[41]为了提高钢铁表面的缺陷分割精度,使用 ResNet50 代替 ResNet18 作为编码模块,提出了一种改进的 Res-UNet 网络分割算法,进行分割训练后, Dice 系数最多提高了 12.64%,达到 0.7930。Liu 等^[42]提出了一种基于改进的 YOLOv8 和 FasterNet 骨干算法的印刷电路板表面缺陷检测方法,在两个公开的 PCB 数据集进行训练后, mPA 值均得到提升,综合性能较好。朱德平等^[43]针对汽车齿轮配件表面缺陷检测存在效率低和精度差的问题,结合 CBAM 注意力模块和 F2C 模块提出了一种基于 YOLOv5 改进的缺陷检测模型 YOLO-CNF,进一步提高了缺陷检测的准确率和精度。窦智等^[44]通过优化 YOLOv7 网络模型中的 ELAN 模块、使用 ACmix 注意力模块以及引入 WIoU 损失函数,提出一种基于改进 YOLOv7 的钢板缺陷检测算法,提高了小目标缺陷的检测精度与准确率。Chen 等^[45]针对铝型材表面图像存在噪声的问题,提出了一种在混合噪声条件下基于残差学习网络以及自注意力机制的缺陷检测方法,该方法提高了铝型材表面缺陷在混合噪声条件下的识别精度。Wang 等^[46]利用深度残差学习的策略思想,融合注意机制和自适应变形卷积,构建特征金字塔结构,提出了一种基于自适应卷积神经网络的铝表面缺陷检测方法,训练结果表明该方法在铝表面缺陷检测方面具有更好的性能。Liu 等^[47]提出了一种自适应图像分割网络(AIS-Net),用于表面缺陷的像素分割,该网络主要由多混洗块扩张卷积(MSDC)、双注意力上下文引导(DACG)和自适应类别预测(ACP)模块组成,有效提高了缺陷检测的准确率。Wang 等^[48]通过在 FPN 层中引入双融合路径来提升 Mask R-CNN 特征金字塔的语义信息,并在 RPN 层使用新的评估度量 CIoU 来克服 IoU 在某些特殊情况下的局限性,使得在进行钢轨表面缺陷检测的 mPA 值提高 0.55%。

Liu 等^[49]基于 Faster R-CNN 网络模型,提出了一种称为 MSC DNet 的钢表面缺陷检测方法,该模型通过嵌入扩张卷积(PADC)架构和特征增强和选择模块(FESM)模块增强信息捕捉能力,实验结果表明,该模型在钢表面缺陷数据集上达到 79.4%的 mPA 准确率,满足检测要求。

(2) 多任务学习

基于卷积神经网络技术的缺陷检测方法已被证明优于传统的机器学习方法,但是单任务网络在某些情况下无法满足实际的检测需求,所以总结以往的研究,提出了多任务学习的方法。多任务学习的核心理念是模型通过共享参数和表示来同时学习多个相关任务,从而提高各个任务的泛化能力。相关研究表明,将多任务学习用于缺陷检测也能带来较好结果。Wang 等^[50]提出了一种基于多视图多任务学习模型的混凝土裂缝检测新方法,该方法不仅能够强调裂纹和非裂纹之间的区别,而且充分考虑了抑制不同裂纹区域的可变性。Gibert 等^[51]在多任务学习框架内组合多个检测器,构建铁路轨道检测的深度多任务学习,提高了铁路紧固件缺陷检测的准确性。Ho 等^[52]将 Faster RCNN 对象检测网络与多任务学习系统集成,用于检测钛垫片表面划痕,实验结果表现良好。Zhang 等^[53]提出了一种端到端的多任务网络,共享同一特征提取网络,使两个任务分别用于对象检测和语义分割,最终在钢表面缺陷数据集上进行训练得到 79.3%的 MIoU 值和 78.3%的 mPA 值。Meng 等^[54]同样通过检测与分割相结合的多任务学习网络提高了模型对钢轨裂纹的分割准确率。Vignesh 等^[55]考虑到像素级分割掩模、对象级边界框和全局图像级分类标签之间的相关性,提出了一种 Defect Aux-Net 的多任务学习框架,对螺纹紧固件表面缺陷数据集进行训练后可得 97.1%的分类准确率、0.926 的分割 Dice 评分以及 0.762 的检测精度。Kang 等^[56]将多任务学习用于检测铁路绝缘子的表面缺陷,通过共享深度卷积神经网络实现绝缘体的分割并完成表面缺陷的检测。Dong 等^[57]提出了一种多任务深度单类卷积神经网络以及一种堆叠式自动编码器,通过对自动编码器和单分类器进行端到端的训练后,该模型能够进行较高准确率的缺陷分类与检测。

1.2.3 刀具缺陷检测研究

目前各种缺陷检测的方法研究越来越多,国内外学者对于机械加工刀具的检测研究主要是关于刀具磨损的检测^[58],而对于刀具缺陷尤其是刀具刀刃缺陷的研究却很少。相关研究中,刘浩等^[59]提出了基于图像差分以及基于 SVM 算法的缺陷检测与分类方法,该算法对刀具表面缺陷的检出率达 97.2%,分类准确率可达 94.3%。Abhishek 等^[60]针对立式加工中心多点刀片的缺陷分类问题,提出了一种基于决策树与监督树算法进行分类的机器学习方法。Zhang 等^[61]提出了一种基于 Yolov3-tiny 改进模型与图像处理的铣刀螺旋刃缺陷检测融合方法,可以有效地检测和评估螺旋切削刃光照下的小缺陷。陈再良等^[62]通过从聚类算法、特征层

和损失函数三方面对 YOLOv3 算法进行改进,使用 k-means++ 算法对锚框重新聚类、添加 104×104 大小的网络特征层、使用 GIoU 替代 IoU 优化损失函数,解决了刀具表面缺陷识别中小目标漏检率较高、标准 YOLOv3 算法边框定位误差大的问题。Shi 等^[63]通过改进 YOLOv5 模型以及迁移学习方法实现了对刀具工件表面缺陷的快速准确检测。Hazzan 等^[64]通过区域卷积神经网络 (R-CNN) 对硬质合金刀具表面缺陷进行识别和分类,并使 R-CNN 的数据与激光参数匹配,训练反向传播神经网络 (BPNN) 作为预测网络 R-CNN 对每个缺陷进行了定量分析,平均准确率为 91%。由于切削刀具种类丰富,目前关于刀具缺陷数据并未建立相应的数据库,而且国内外学者对于刀具缺陷的研究主要集中于刀具表面,而刀具刀刃是切削加工过程中影响产品质量的主要因素,所以为了更加智能化地实现刀具刀刃缺陷的识别与检测,仍需进一步开展关于刀刃缺陷的机器学习方法研究。

针对刀具刀刃缺陷检测存在的问题,本文以圆形机夹式车刀为例,提出了一种结合图像处理与深度学习的圆形机夹式车刀刀刃缺陷检测方法,目的是实现刀具刀刃的智能化检测并提高检测精度与准确率。

1.3 研究内容及技术路线

1.3.1 研究内容

本文采集的图像数据集中包含了多种类型的缺陷,其中刀刃剥落类缺陷占比较大。因此,本研究主要聚焦于存在剥落类缺陷的圆形车刀和无缺陷的圆形车刀,将图像分为不合格与合格两类。由于圆形车刀表面轮廓或缺陷的影响,直接使用原始采集的图像作为输入会导致模型对刀刃缺陷的检测精度较低,所以采用了一种图像处理方法提取出圆形车刀的刀刃轮廓图片作为模型输入,并使用改进的 Xception 模型作二分类单任务学习。分类任务主要关注于全局信息,而分割任务更加侧重于局部信息,单任务分割模型在分割圆形车刀刀刃缺陷时表现不佳,所以在研究过程中建立了多任务模型,将分类任务与分割任务相结合,提高分割任务的检测精度。主要研究内容如下:

(1) 由于圆形车刀刀刃缺陷的图像数据集不易采集,所以在图像采集过程中使用了多种类型的圆形机夹式车刀,但是这会造成图像表面的花纹轮廓不统一以及缺陷斑点等噪声的影响,进而导致模型的准确率下降。为了解决此问题,本文通过图像增强、二值化处理、连通域处理以及形态学处理等方法将圆形机夹式车刀的刀刃轮廓边缘分离出来作为模型输入,以减少噪声的干扰。考虑到刀刃缺陷形态大小差异大等问题,模型建立过程中将 Xception 网络的低层次信息与深层次信息进行融合,并在融合之前引入 CBAM 注意力模块以增强特征提取能力,保证模型能够有效捕捉不同尺度的特征并提高对小目标特征的检测率,提升模型

的泛化能力。

(2) 针对单任务分割模型对圆形机夹式车刀刀刃缺陷分割不充分且精度低的问题, 本文以 Xception 网络为基线模型对 U-Net 模型进行改进, 进而构建分割与分类的多任务网络模型, 实现模型对局部信息与全局信息的关注。为了提升网络模型整合多尺度信息的能力并且丰富提取到的缺陷特征信息, 在进行分割任务时, 骨干网络 Xception 在融入 FPN 架构后再进行跳跃连接; 跳跃连接过程中, 为了减少冗余的特征信息, 使用了 Attention Gates 注意力机制, 使模型能够针对性地提取到缺陷特征; 最后在改进 U-Net 网络的解码器上采样最后一层完成对缺陷的分割预测。与此同时, 将骨干网络 Xception 进行多尺度信息融合并加入 CBAM 注意力模块, 实现分类预测。

(3) 为了在机械制造生产过程中能够快速判断刀具是否合格可用, 结合上述两个模型, 搭建了一套圆形机夹式车刀刀刃缺陷检测平台。该平台通过上传圆形车刀图片, 能够自动处理图片, 然后判断刀具是否合格并对不合格刀具进行缺陷分割。该系统能够在一定程度上为机械加工生产提供参考作用, 解决人工目测的不足, 提高分检效率。

1.3.2 技术路线

为了研究圆形机夹式车刀刀刃的缺陷检测, 本文的技术路线如图 1-2 所示。




图 1-2 技术路线

Fig. 1-2 Technical route

1.4 报告章节安排

结构安排如下：

第一章：绪论。主要介绍缺陷检测的研究背景与意义，分析和总结国内外学者对缺陷检测的研究进展，同时提出当前刀具刀刃缺陷检测存在的不足与问题，最后针对该问题提出相应的解决方案，以及本文的研究内容、技术路线以及报告的章节安排。

第二章：刀具缺陷检测基本原理。主要介绍研究内容所用到的深度学习基础理论，包括：卷积神经网络基础理论、部分特征提取算法以及注意力机制，并对所用的图像处理方法进行说明，包括：图像增强处理、二值化处理以及形态学处理，为后续刀具刀刃缺陷检测的研究提供一定的基础理论。

第三章：基于改进 Xception 模型的圆形机夹式车刀分类方法研究。简单介绍 Xception 网络结构，在此基础上将 Xception 网络的低层次信息与深层次信息进行融合，并在融合之前引入 CBAM 注意力模块，进而构建改进的分类模型 X-CBAM，同时介绍使用图像处理方法提取圆形机夹式车刀刀刃轮廓的过程，最后通过实验验证本章方法在对圆形机夹式车刀进行二分类的有效性。

第四章：基于多任务学习的刀具缺陷分割。首先简单介绍多任务学习的理论基础，然后以 Xception 网络为基线模型对 U-Net 模型进行改进，在此基础上融入 FPN 架构以及 Attention Gates 注意力机制进行进一步的改进和优化，进而构建分割与分类的多任务网络模型 Multi-UF-Xception，并通过学习率衰减以及损失加权的方法提升模型精度，最后通过实验验证本章方法对圆形机夹式车刀进行缺陷分割的有效性。

第五章：刀具缺陷识别系统设计。本章主要是根据前两章研究的刀具缺陷检测算法搭建刀具缺陷识别系统平台，通过平台调用分类与分割的两种算法，进一步检验本文研究内容的有效性。

第六章：总结与展望。对本文刀具缺陷检测的研究进行概括总结，提出相应的改进策略和建议，并展望未来研究方向和发展趋势。

2. 刀具缺陷检测基本原理

刀具缺陷检测需要进行合理的图像处理以及模型建立。深度学习模型拥有强大的图像特征学习能力,结合图像处理技术可以有效提取图像中的关键结构信息,从而显著增强模型的准确性和可靠性。因此,本章将介绍研究工作过程中涉及到的深度学习相关基础以及使用到的图像处理相关理论,为后续刀具图像的处理以及检测模型的建立奠定基础。

2.1 图像处理方法

2.1.1 图像增强处理

在对缺陷图片进行训练之前,为了使缺陷轮廓、刀具轮廓等特征更加明显,可以使用图像增强方法^[65]对灰度图进行增强。常用的图像增强方法主要有直方图正规化^[66]、直方图均衡化^[67]、伽马变换^[68]等。所谓灰度直方图即表示不同灰度级所包含像素值的个数,图 2-1 为不同方法下的灰度直方图。




图 2-1 不同方法下的灰度直方图

(a) 原灰度直方图; (b) 直方图正规化; (c) 直方图均衡化

Fig. 2-1 Gray-Level histograms under different methods (a) Original Gray-Level histogram; (b) Histogram normalization; (c) Histogram equalization

(1) 直方图正规化: 该方法的目的是将图像原有的灰度值分布按照灰度映射规则使灰度值分布更加均匀,以增强某些灰度图像的对比度以及亮度。原灰度直方图在经过直方图正规化后会变为如图 2-1 (b) 所示的直方图。

(2) 直方图均衡化: 直方图均衡化又可分为全局直方图均衡化和自适应直方图均衡化,可以将原图像的直方图改变得更加均匀。由于灰度图会出现偏暗、偏亮等情况即像素值比较集中于某一范围内,所以为了增强图像全局的对比度,全局直方图均衡化将原有的极端像素值分布映射为均匀分布的像素值;自适应直方图均衡化是对全局直方图均衡化的改进,通过将图像划分成多个区域,然后对每一个区域进行直方图均衡化,这样保证了图像局部的对比度,更能体现局部特征,但是可能出现区域之间对比度过于明显的情况。原灰度直方图在经过直方图均衡化后会变为如图 2-1 (c) 所示的直方图。

伽马变换: 伽马变换主要是通过非线性操作调整图像的对比度,当伽马值小于 1

时，输出图像会显得更亮；而当伽马值大于 1 时，图像会变暗。

2.1.2 二值化处理

二值化图像处理是将灰度图像的像素点值转化为 0 和 255（黑白）二值的方法，可用于图像的轮廓分割处理，其二值化的方法主要有固定阈值法、自适应阈值法以及 Otsu 阈值法等^[69]。

（1）固定阈值法：该方法就是通过设定固定的像素阈值进行二值化处理。假设像素阈值为 127，那么图像中像素值大于或等于 127 的像素值统统转换为 255（白色），而小于 127 的像素值则转换为 0（黑色），这样就对图像进行了二值化处理。

（2）自适应阈值法：对于图像上各区域像素值对比较大的场景，自适应阈值法会将图像划分为多个区域，然后通过均值法或高斯法计算每一个区域的阈值，再根据阈值对该区域进行二值化处理。

（3）Otsu 阈值法：适合将图像中前景与背景进行区分，是一种全局阈值方法，它将图像中每一种灰度级像素值都作为阈值，之后以每一个阈值为分割线将图像分为两部分，再根据两部分的像素值求解出一个以该阈值为基础的类间方差^[70]。由于前景与背景的像素值存在显著差异，当类间方差达到最大时所对应的像素阈值即为理想的分割阈值。利用这一阈值进行二值化处理，可以有效地将前景与背景区分开来。

2.1.3 形态学处理

二值图像形态学处理^[71]方法原理为，使用 $n \times n$ 矩阵结构单位，矩阵结构元素原点遍历图像中白值连通域边缘的像素值点，腐蚀即将连通域与矩阵结构元素原点重合的地方像素值设置为 0，膨胀即将连通域周围与结构单位重合的地方像素值设置为 255。

如图 2-4 中使用 3×3 的矩阵结构单位对待处理区域中蓝色区连通域进行处理，1 表示像素值为 255，0 表示像素值为 0。将 3×3 的矩阵结构元素原点 1（深红色方块）遍历待处理区域中蓝色区域中的每一个像素值点，图中三处橙色部分 3×3 矩阵所围区域表示矩阵结构元覆盖到待处理区域中，其中每一个浅蓝色方块表示矩阵结构元素原点 1 与待处理区域中的像素值点 1 的中心重合点。

腐蚀过程中，若矩阵结构元在遍历过程中覆盖区域有像素值点 0，则将待处理区域中像素值为 1 的中心重合点改变为 0，若矩阵结构元在遍历过程中覆盖区域只有像素值点 1，则待处理区域中像素值为 1 的中心重合点不变。

膨胀过程中，矩阵结构元素原点 1 遍历待处理区域中每一个像素值点，将覆盖区域中心重合点 1 的周围像素值点全转换为 1。




图 2-2 形态学处理过程

Fig. 2-2 Morphological processing steps

2.2 深度学习基础理论

2.2.1 卷积神经网络基础理论

神经网络的概念及其灵感来源于对生物神经系统工作方式的^[72]理解，其发展是一个渐进的过程，涉及众多科学家和研究者的贡献，而卷积神经网络是受到生物视觉系统的启发，通过模拟人类视觉对图像处理方式，逐层提取图像特征以完成对图像信息的处理，实现对图像的识别与检测。在人类视觉系统中，视网膜上的每个点仅接收来自其周围小范围内的光线信息，即所谓的“局部感受野”，类似地，卷积神经网络则通过卷积核在图像的局部区域进行操作，这一局部区域即感受野。在卷积神经网络中，感受野的存在十分重要，感受野大，神经元则捕捉整体结构信息；感受野小，神经元能够捕捉到局部细节信息。感受野计算公式为式 2-1 所示：

$$R_n = R_{n-1} + (k_n - 1) \cdot s_{n-1} \quad (2-1)$$

其中 R_n 为第 n 层感受野大小， R_{n-1} 为第 $n-1$ 层感受野大小， k_n 为第 n 层卷积核大小， s_{n-1} 为第 $n-1$ 层步长大小。

卷积神经网络模型的搭建十分复杂，对缺陷的检测精度与准确率也依赖于模型的搭建程度，卷积神经网络通常由卷积层、批归一化层、激活层、池化层和全连接层组成^[73]，特定情况下也包括正则化技术、上采样层等。

(1) 卷积层：该层由多个相同大小卷积核组成，其卷积核的数量、大小以及步长大小、填充方式决定了该层的特征提取能力。每个卷积核在输入的图像上按照固定步长滑动，每滑动一次就对其覆盖区域的像素值进行加权求和，直至遍历整个图片后，则提取出相应的特征图。由于卷积层具有权值共享与随机初始化权重的特点，所以每一个卷积核滑动的步长以及填充方式是相同的，但是每一个卷积核的初始化参数可能不同，这保证了每一个卷积核能够通过学习捕捉输入图像上的不同特征。

卷积核的加权求和方式如图 2-3 所示，假设步长为 1，填充为 0，使用 3×3 的卷积核对输入图像进行卷积操作，卷积核上的元素与其在图像上覆盖区域的元素对应相乘再求和得到该区域的特征值。卷积核按照步长滑动，遍历整个图像即可得到相应的特征图。




图 2-3 卷积操作图

Fig. 2-3 Convolution operation diagram

(2) 激活层：卷积神经网络中的激活层类似于生物视觉系统中的激活机制，当提取的特征强度达到某一阈值时，才能将此特征输出，否则可能没有提取到特征而输出，这是不合理的，激活函数则保证了特征提取的合理性。图像识别过程中很多特征都是非线性的，激活函数通过引入非线性元素使网络模型能学习到复杂的非线性映射即复杂的特征，这大大增强了模型的泛化能力和表达能力。常用的激活函数^[74]主要有 Sigmoid、Relu、Tanh 和 Softmax 等函数。

Sigmoid 函数的特征映射在 $[0,1]$ 之间，适合用于作二分类任务的概率预测，其表达式如公式 2-2：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-2)$$

Relu 函数为线性整流函数，实际时一个分段函数。输入 x 小于 0 时，输出恒为 0，可能导致神经元不更新；输入 x 大于 0 时，输出为 x ，有效防止了梯度消失。其表达式如公式 2-3：

$$f(x) = \max(0, x) \quad (2-3)$$

Tanh 函数为双曲正切函数，其特征映射在 $[-1,1]$ 之间，相较于 Sigmoid 函数，Tanh 函数的输出是以零为中心的，收敛速度更快。其表达式如公式 2-4：

$$f(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}} \quad (2-4)$$

Softmax 函数适用于作多分类任务的概率预测，特征映射在 $[0,1]$ 之间，其表达式如公式 2-5:

$$f(x) = \frac{e^{x_i}}{\sum_{j=1} e^{x_j}} \quad (2-5)$$

(3) 批归一化 (Batch Normalization, BN) 层: 在卷积训练过程中, 每一层的参数变化都会产生新的输出, 然后输入下一层, 这样会造成内部协变量偏移, 进而导致模型训练速度变慢。为了将每层的输入重新调整到一个相对稳定的分布 (通常是均值为 0, 方差为 1 的标准正态分布), 通常把 BN 层置于卷积层或全连接层之后, 进而能够对每一批次的数据进行归一化处理, 以此提高模型的稳定性和泛化能力。因为 BN 层保持了每一层输入的稳定性的, 所以在训练时可以使用更高的学习率而不必担心梯度爆炸或消失的问题, 使训练更加平滑并提高了训练速度; 同时 BN 层具有一定正则化效果, 在一定程度上可以减少其他正则化技术的使用, 用以防止过拟合。BN 层一般与卷积层或全连接层、激活层同时使用。

(4) 池化层: 该层在减小特征图空间尺寸的同时保留了重要特征, 这样不仅减少模型所需计算的参数量, 还在一定程度上防止了过拟合, 使模型具有更强的泛化能力。同时, 池化层通过下采样操作有效的扩大了后续层的感受野, 使模型能够在更深的层次上捕捉到更大范围内的特征。下采样过程与池化层大小、步长以及池化方法有关, 常见的池化方法主要有最大池化、平均池化等池化方法。




图 2-4 池化操作图

Fig. 2-4 Pooling operation diagram

池化过程如图 2-4 所示, 假设池化层大小为 2×2 矩阵, 步长为 1, 使其在特征图上滑动。最大池化则取特征图上覆盖区域中的元素最大值为该区域特征值; 平均池化则取特征图上覆盖区域元素的平均值为该区域特征值。池化层按照步长滑动, 遍历整个图像即可得到相应的特征图, 该特征图保留了重要特征。

(5) 全连接层: 全连接层与卷积层的核心差异体现在神经元连接方式及特征提取特性上。全连接层的每个神经元均与前一层所有神经元建立连接, 从而整

合全局信息，而卷积层通过局部感受野机制，专注于提取图像的区域特征。在卷积神经网络架构中，全连接层通常部署于网络末尾，其作用是将卷积层输出的局部特征融合为整体特征表示。当应用于分类任务时，通过在最终全连接层后添加 Softmax 激活函数，可将输出结果映射为符合概率分布的类别预测值（各输出节点的取值范围被约束在[0,1]区间内）。

上采样层：上采样层的作用即增加特征图的空间尺寸，提高图像分辨率，主要用于图像分割、多尺度特征融合、生成对抗网络等过程中。上采样不是下采样的逆操作，而是通过插值方法实现特征图放大的过程，主要的插值方法有最邻近插值、双线性插值、双三次插值以及转置卷积。

2.2.2 特征提取算法

（1）MobileNet 模型：MobileNet^[75]是一种轻量化特征提取网络，其能够减少了参数量和计算量主要归功于深度可分离卷积（depthwise separable convolution）。到目前为止，MobileNet 经历三个版本的变化。最初，MobileNetV1 在 2017 年首次引入深度可分离卷积，MobileNetV2^[76]在第二年增加了线性瓶颈结构与反向残差结构，到 2019 年，在利用神经架构搜索（Neural Architecture Search, NAS）改进网络结构和参数以及删除网络末端部分层之后，又引入了通道注意力模块（SE）以及 H-Swish 激活函数，得到计算量更小、精度更高的 MobileNetV3^[77]模型，MobileNetV3 模型又分为 MobileNetV3-Large 以及 MobileNetV3-Small 两类，分别适用于性能较好的平台与性能较低的平台。但是 MobileNet 相较于复杂的网络结构，其特征提取能力相对较弱。

（2）Xception 模型：Xception^[78]的核心也是深度可分离卷积，而且 Xception 也是经历了 Inception 的改进得到的，也被称为极端的 Inception。Xception 模型本身是一种深度残差网络，它在 ImageNet 数据集上表现出色，并且具有许多堆叠的深度可分离卷积层以及线性残差连接的架构，深度可分离卷积层可有效减少参数量即减少训练时间，利用残差网络的思想可以帮助模型更好地学习深层特征与浅层特征的关系，所以 Xception 相对 InceptionV3^[79]具有分类精度高、计算量小以及泛化能力强的特点，而且相对具有同样深度可分离卷积的 MobileNet 而言，具有更强的特征提取能力。

（3）ResNet 模型：ResNet（Residual Network）是由何凯明团队（隶属于微软研究院）于 2015 年提出的一种深层卷积神经网络结构^[80]。其核心创新在于引入了“残差学习”框架，通过残差块（Residual Block）设计有效缓解了深层网络训练中梯度消失与梯度爆炸的难题，显著提升了模型的训练稳定性。这一突破性设计不仅成为后续深度网络架构的基石，更推动了深度学习技术的快速发展。ResNet 系列包含多种深度变体，如 ResNet-18、ResNet-34、ResNet-50、ResNet-

101 及 ResNet-152, 不同变体主要通过调整网络层级深度与模块组合方式实现性能与效率的平衡。

U-Net 模型: U-Net 模型^[81]主要用于图像分割任务中, 该模型拥有独特的编码-解码结构以及跳跃连接 (skip connection), 常常用作进行改进的基础模型。U-Net 模型编码器 (Encoder) 部分其实是一段下采样的特征提取过程, 解码器 (Decoder) 部分中的上采样可以将特征进行分割, 跳跃连接采用 Concatenate 函数将两者对应层级的特征进行融合, 丰富多尺度信息, 实现特征分割。

2.2.3 注意力机制

注意力机制可以让模型聚焦于输入数据中的关键部分^[82], 在刀具刀刃缺陷的检测过程中, 注意力模块有助于模型对微小或复杂的缺陷进行识别并且能够突出缺陷特征。在卷积网络模型进行特征提取的过程中, 随着模型层次的深入, 提取到的刀具特征越来越模糊, 这造成了特征信息的丢失, 通过引入注意力模块能够使深层次信息更加容易被注意到, 提高了模型的特征提取能力, 从而使模型在刀具缺陷检测中表现地更加出色。关于注意力机制的研究很多, 其中常用的注意力模块为通道注意力模块以及空间注意力模块 (SA), 它们分别从通道和空间维度对特征图进行加权处理, 以增强模型的表现力和鲁棒性。

(1) 通道注意力模块: SE 模块是一种用于增强卷积神经网络特征表示能力的技术, 它由 Jie Hu 等人在 2018 年提出^[83]。该模块通过动态调整特征图中各通道的重要性权重, 实现对关键信息的强化与冗余信息的抑制。其核心机制包含三个关键步骤: 压缩 (Squeeze) 操作、激励 (Excitation) 操作以及重加权 (Re-weighting) 操作。

(2) 空间注意力模块: SA 模块是 CBAM 注意力机制中的关键组件, 其核心理念是通过空间维度的动态加权机制来增强特征图中有效区域的表达, 同时抑制无关背景噪声。具体实现流程包括三个阶段: 特征图聚合 (Feature Map Aggregation)、拼接与卷积 (Concatenation and Convolution) 以及注意力应用 (Attention Application)。

2.2.4 多任务学习

多任务学习 (Multi-Task Learning, MTL) 是一种机器学习方法, 从生物角度看, 多任务学习就如同人类学习新知识时, 往往会从已学的知识中得到启发。多任务学习的概念可追溯到上世纪 90 年代, 它的基本原理是通过共享模型参数和特征表示来同步学习多个相互关联的任务, 从而增强每个任务的表现和通用性。例如, 刀具刀刃的缺陷识别过程中, 一个模型用于刀具刀刃的缺陷分类, 一个模型用于刀具刀刃的缺陷分割, 两个模型可能在各自的任务上能表现出较好的性能效果, 但是他们无法学习到彼此相关的信息, 所以通过多任务学习模型将两个任

务进行关联学习，能够提高单个任务上的训练精度与准确率。

多任务学习的特点是，相关任务通过关联学习可以相互提高学习性能以及学习精度，同时具有一定的正则化效果，能够有效减少单个任务出现过拟合的现象，而且多个任务联合学习还能够减少资源利用，加快学习速度。但是使用多任务学习时需要注意的是，不同任务之间一定要有相关性，否则可能出现训练效果变差的现象，而且相关任务收敛速度可能不一样，其中一个任务过拟合，另一个任务可能还未拟合，所以训练时需要平衡任务权重，比如调整两个任务损失函数的权重比例使两个任务能够同时拟合。多任务学习主要通过共享参数实现，所以按照共享参数时的网络架构以及共享程度，将其分为硬参数共享与软参数共享两种方式^[84]。

硬参数共享是多任务学习常用的共享参数方式，其所有任务共享同一神经网络结构的主体部分，而在输出部分保留各个任务的网络分支即保留独立参数，网络架构如图 2-5 所示。比如不同任务共享卷积神经网络模型下采样部分，从输入层到下采样结束时共享相同参数，从彼此的数据中提取通用特征，然后在各自任务分支中学习共享的特征，提高模型的泛化能力，并且减少参数量以及过拟合风险。但是硬参数共享不适用于相关性较低的多任务学习，训练效果较差。




图 2-5 硬参数共享

Fig. 2-5 Hard parameter sharing

软参数共享与硬参数共享最大的区别是各个任务拥有各自的主体结构，但是又通过某些机制使两种独立的网络相关联，实现参数共享，这可以通过施加正则化技术、添加注意力机制或者设计特定的模块来实现，如图 2-6 所示。与硬参数共享相比，软参数共享在灵活性和适应性上更具优势，适合于那些既有关联又各自独特的任务，可以在不牺牲太多性能的情况下更好地适应每个任务的特点。但是需要注意的是，软参数共享的设计更加复杂，需合理设计参数关联机制，并且需要仔细考虑优化策略。




图 2-6 软参数共享

Fig. 2-6 Soft parameter sharing

2.3 刀具图像数据集采集

2.3.1 刀具类型

本文采集的刀具刀刃缺陷均来自企业机械加工时使用的圆形机夹式车刀，尺寸大小为 R8（半径 8 mm），主要是通过刀垫、刀具螺丝、夹紧元件将刀具紧固在刀杆上。本文所使用的圆形机夹式车刀类型如图 2-7 所示，图中车刀拥有不同的表面花纹轮廓。



图 2-7 圆形机夹式车刀类型

Fig. 2-7 Circular machine clamp tool types

2.3.2 图像采集

在现代工业检测领域，形状测量激光显微镜系统作为图像数据采集的关键工具，因其卓越的高精度和非接触式测量特性而备受青睐，如图 2-8 所示。这类设备不仅能够提供样品表面详尽的三维形貌信息，还能够对细微结构进行精确的分析，适用于从纳米级到毫米级范围内的各种测量需求。该显微检测系统融合了多种尖端扫描技术，涵盖激光共聚焦、白光干涉及聚焦变化等核心原理。通过多技

术协同运作，系统实现了非接触式、无损检测能力，可精准测量高至低倍率的微观形貌特征。其适用范围广泛，既可分析平面与复杂凹凸表面的纳米级粗糙度，亦能应对镜面材料、透明介质等特殊样品的三维形貌表征，显著扩展了精密测量的场景适应性与数据维度。



图 2-8 形状测量激光显微镜系统

Fig. 2-8 Shape measurement laser microscope system

表 2-1 形状测量激光显微镜系统相关参数

Table 2-1 Shape measurement laser microscope system parameters

名称		参数
总放大倍率		28800 倍
物镜		六孔电动物镜转换
物镜倍数		2.5、5、10、20（NA≥0.46）、50（NA≥0.95）、150 倍
整体观测视野范围		11 um-7398 um



图 2-9 图像拍摄过程

Fig. 2-9 Image capture process

因此，本文采集刀具刀刃缺陷图像数据的主要工具是型号为 Keyence VK-X1100 的形状测量激光显微镜系统，该设备可放大倍率超过 24000 倍，能够观测到的视野范围为 11-7398 微米。将刀具放置于物镜下的置物台上，通过调节显微镜的放大倍数、焦距等参数以及光源亮度来保证拍摄图像的质量，这一步对缺陷

检测至关重要，相关参数如表 2-1 所示。由于显微镜放大 50 倍时，图像上就能够清晰的观察到刀具刀刃缺陷，但是只能拍摄到刀具的一部分刀刃，并未完整拍摄整个刀具，所以该设备采用 4×5 的拼接工具，将刀具分为 20 个区域进行拍摄，然后拼接成完整刀具，拍摄过程如图 2-9 所示。最后采集到的刀具图像数据集一共 180 张，其中合格类有 98 张，不合格类有 82 张。

2.4 本章小结

本章主要介绍了刀具缺陷检测研究所依赖的基本原理，涵盖了深度学习的基础理论和图像处理的核心方法。在深度学习方面，详细阐述了卷积神经网络的基本结构、特征提取算法以及注意力机制，这些内容为后续模型的建立与改进奠定了坚实的理论基础。对于图像处理，探讨了包括图像增强、二值化处理和形态学处理在内的基本方法，这些技术为后续的图像预处理提供了必要的支持。

3. 基于改进 Xception 模型的圆形刀具缺陷分类方法研究

一般情况下，建立深度学习缺陷检测模型后即可带入图像数据进行训练，但是圆形机夹式车刀表面花纹轮廓不同，表面轮廓及缺陷影响模型对刀刃缺陷的判断。因此，为了实现刀具表面的高精度分类，本章提出了一种刀刃轮廓提取的图像预处理方法，提取刀刃轮廓作为模型输入，然后以 Xception 预训练模型为基准模型，将深层次信息与低层次信息进行多层特征融合，同时引入 CBAM 注意力机制增强不同层级对刀具缺陷特征的关注度，最后经过全连接层后实现刀具合格或不合格的分类。

3.1 改进的 X-CBAM 分类模型网络设计

3.1.1 Xception 模型介绍

Xception 模型的核心创新在于引入了深度可分离卷积（Depthwise Separable Convolution），以替代 InceptionV3 中经典的多尺度并行卷积结构。具体而言，InceptionV3 通过并行堆叠不同尺寸的卷积核（如 1×1 、 3×3 、 5×5 ）来捕捉多尺度特征，但这种设计导致参数量显著增加。Xception 通过深度可分离卷积，首先对每个输入通道单独进行空间卷积（深度卷积），再通过 1×1 卷积融合通道间特征（逐点卷积），在保持多尺度特征提取能力的同时，将参数量减少了约 30%。这种设计不仅降低了计算复杂度，还通过更精细的特征解耦提升了模型的表达能力。Xception 模型主要分为 3 个部分，如图 3-1 所示，分别是入口层（Entry flow）、中间层（Middle flow）、出口层（Exit flow），一共有 36 个卷积层，并且可以分为 14 个基本结构单元（block），除了第一个 block 与最后一个 block 以外，其余部分均同时拥有深度可分离卷积层与线性残差结构。

Xception 模型通过引入深度可分离卷积，显著减少了计算量和参数数量，同时保持了强大的特征提取能力，其中，Entry Flow 负责初步的特征提取和下采样，通过深度可分离卷积对输入图像进行多尺度特征解码，主要由几个残差块组成，每个残差块包含深度可分离卷积和标准卷积操作；Middle Flow 负责进一步提取和细化特征，它由 8 个相同的残差块组成，每个残差块不改变空间尺寸，只增加通道数；Exit Flow 整合并聚合深层特征，负责最终的特征提取和分类，包含两个残差块，最后一个深度可分离卷积层连接全局平均池化层和全连接层。简而言之，Xception 模型架构是一个具有残差连接的深度可分离卷积层的线性堆栈。

相关研究表明，在使用 ImageNet 图库对 Xception 模型进行分类训练实验后，Xception 模型的分类效果明显优于 VGG-16、ResNet152 以及 InceptionV3 等模型，所以本文选用 Xception 模型作为刀具缺陷二分类的基准模型，在此基础上对模型作进一步的改进，以提升对刀具缺陷的分类性能。




图 3-1 Xception 网络结构图

Fig. 3-1 Xception network structure diagram

(1) 深度可分离卷积: 传统神经网络对一个输入只使用一个卷积核, 而使用不同大小的卷积层可以提取到不同的信息, 但是卷积核数量过多会增加滤波器的数量, 进而导致参数量爆炸, 使得计算困难, 通过深度可分离卷积的思想可解决此问题, 并提取更多特征信息。深度可分离卷积包括逐点卷积和深度卷积, 逐点卷积使用 $1 \times 1 \times n$ 的卷积核对输入特征中的每一个空间 (长 $\times$ 宽) 进行跨通道信息的提取, 堆叠过后使用 n 个 $3 \times 3 \times 1$ 的卷积核提取输入特征中不同的通道信息, 再次堆叠过后即得到一个深度可分离卷积模块的输出特征, 特征结构图如图 3-2 所示。

(2) 残差结构: 残差网络思想^[81]是为了解决随着模型层数增加出现特征退化的问题, 通过跳跃连接能将每一层的输入传递到更深层次, 防止梯度消失, 从而提高模型性能, Xception 中的残差结构如图 3-3 所示。




图 3-2 深度可分离卷积过程

Fig. 3-2 Depthwise separable convolution process




图 3-3 残差结构

Fig. 3-3 Residual structure

3.1.2 CBAM 注意力模块

CBAM (Convolutional Block Attention Module) ^[85] 是一种轻量级前向注意力机制,通过串联通道注意力模块与空间注意力模块实现特征增强,如图 3-4 所示。该设计实现了通道与空间维度的协同优化,在图像分类、目标检测等任务中展现出优异的性能增益,而且因为其是一种轻量级模块,所以在 CNN 架构中的计算量可以忽略不计。

通道注意力模块聚焦于通道维度,如图 3-5 所示。通过对 $H \times W \times C$ 的特征图 F 分别进行全局平均池化和全局最大池化,减少特征图尺寸参数,得到两个 $1 \times 1 \times C$ 的特征向量,之后将两个特征向量分别输入共享网络 (MLP 网络),该网络由神经元个数分别为 C/r (r 为缩减比,可人为设置且 $r \geq 1$) 和 C 的两个全连接层组成。通过共享网络分别输出两个特征向量后,使用同位元素相加后采用

Sigmoid 函数的方法，输出注意力加权后的通道特征 W_c 。将刚开始输入的特征图与通过通道注意力模块输出的通道特征进行同位元素相乘的处理即可得到空间注意力模块需要的输入特征图 F_c ($H \times W \times C$)。通道注意力特征计算如公式 3-1 所示：




图 3-4 CBAM 注意力模块

Fig. 3-4 CBAM attention module

$$W_c = \delta(\text{MLP}(\text{Avgpool}(F)) \oplus \text{MLP}(\text{Maxpool}(F))) = \delta(W_1(W_0(F_{\text{Avg}})) \oplus W_1(W_0(F_{\text{Max}})))$$

$$F_c = W_c \otimes F \quad (3-1)$$

其中， δ 为 Sigmoid 函数， W_1 和 W_0 为共享网络 MLP 权重。 F_{Avg} 、 F_{Max} 分别为特征图 F 经过全局平均池化和全局最大池化后的向量。




图 3-5 通道注意力模块

Fig. 3-5 Channel attention module

空间注意力模块（Spatial attention module）重点关注空间维度，如图 3-6 所示。首先将通过通道注意力模块输出的特征图 F_c 分别进行通道维度的全局平均池化和全局最大池化，得到两个 $H \times W \times 1$ 的特征向量，之后将两个向量进行堆叠操作得到 $H \times W \times 2$ 的特征向量。然后采用卷积核为 7×7 的卷积层将特征向量降维为一个通道，即 $H \times W \times 1$ 。降维后通过 Sigmoid 函数输出注意力加权后的空间特征 W_s 。将通过通道注意力模块输出的特征图与通过空间注意力模块输出的空间

特征进行同位元素相乘的处理即可得到 CBAM 特征图 F_s ($H \times W \times C$)。空间注意力特征计算如公式 3-2 所示。

$$W_s = \delta \left(f^{7 \times 7} \left(\left[\text{Avgpool}(F_c); \text{Maxpool}(F_c) \right] \right) \right) = \delta \left(f^{7 \times 7} (F_{\text{Avg}}; F_{\text{Max}}) \right)$$

$$F_s = W_s \otimes F_c \quad (3-2)$$

其中, δ 为 Sigmoid 函数, $f^{7 \times 7}$ 为滤波器大小为 7×7 的卷积核。 F_{Avg} 、 F_{Max} 分别为特征图 F_c 经过通道维度的全局平均池化和全局最大池化后的向量。




图 3-6 空间注意力模块

Fig. 3-6 Spatial attention module

3.1.3 改进模型 X-CBAM 整体网络结构

采用基于模型的迁移学习方法, 使用 Xception 用 ImageNet 图库事先训练的权重作为预训练模型的权重, 不保留 Xception 的全连接网络, 特征提取网络部分的模型参数如表 3-1 所示。迁移 Xception 后还需对模型进行微调, 模型微调时冻结最后十层, 这些层的权重不会因为训练而改变, 这样可以充分利用预训练模型学到的特征, 同时加快训练的速度。添加 CBAM 注意力模块可以帮助模型更好地捕捉图像中的重要信息, 提高模型的准确性和泛化能力, 帮助模型更好地理解 and 处理图像数据。因此为了模型能够关注到刀具图片上的小目标缺陷特征, 使 Xception 模型与 CBAM 注意力模块融合在一起, 在 Xception 的 block1_1 的卷积层、block4_1 的深度可分离卷积层、block7_1 的深度可分离卷积层、block10_1 的深度可分离卷积层以及 block14_2 的输出部分增添 CABM 注意力模块, 经注意力模块输出后, 增添滤波器为 256 的卷积层并且作下采样处理, 使五个模块输出的特征图维数相同以便作拼接处理, 这样可以将深层与浅层信息整合在一起, 从而实现多层次特征融合, 提高模型对输入数据的理解和处理能力, 具体结构如图 3-7 所示。




图 3-7 改进 Xception 整体网络结构

Fig. 3-7 Improved Xception overall network structure

表 3-1 Xception 特征提取网络部分模型参数

Table 3-1 Xception feature extraction network model parameters

网络结构层	卷积核
卷积层 1；卷积层 2	$3 \times 3, 32; 3 \times 3, 64$
深度可分离卷积层 1-3	$[3 \times 3, 128] \times 2, [3 \times 3, 256] \times 2; [3 \times 3, 728] \times 2$
深度可分离卷积层 4-11	$[[3 \times 3, 728] \times 3] \times 8$
深度可分离卷积层 12-14	$\begin{bmatrix} 3 \times 3, 728 \\ 3 \times 3, 1024 \end{bmatrix}; [3 \times 3, 1536]; [3 \times 3, 2048]$

3.2 数据预处理

将数据集输入模型进行训练之前，必须进行数据集预处理，预处理的方式主要包括划分数据集和图像处理。

3.2.1 数据划分

圆形机夹式车刀在加工过程中常常会因为使用时间、温度、被切削材料等问题出现刀刃磨损、剥落、崩刃、塑性变形等缺陷，但是实际加工过程中出现的缺陷类型十分复杂，而且适合于训练的刀具刀刃缺陷图片不易采集、各类圆形机夹式车刀的表面花纹轮廓不同，使得刀具刀刃缺陷检测十分困难。生产过程中，进行刀具缺陷检测主要是为了防止刀刃缺陷影响产品生产质量，所以可以将刀具缺陷检测定义为一种二分类问题即判断刀具是否合格，这样有效地解决了刀具刀刃

缺陷类型复杂而且数据量少导致的不易分类问题,也减少了后续对图像处理的工作量,同时也能满足生产要求。本章主要以存在剥落类缺陷的圆形车刀以及无缺陷的圆形车刀为研究对象,将图像分为不合格类与合格类。

共采集到 180 张刀具图像数据,其中合格类有 98 张,不合格类有 82 张。划分数据集时以其中 80%为训练集,20%为测试集。划分后,训练集中合格类有 78 张,不合格类有 66 张,测试集中合格类有 20 张,不合格类有 16 张。

3.2.2 刀刃轮廓提取

进行图像处理时,需要采用数据增强方法扩增数据集,一般只需对训练集进行数据增强处理,通过随机旋转 45 度、水平移动 20%、垂直移动 20%、水平翻转和垂直翻转的方法来处理图像。针对刀具类型不一、表面轮廓复杂的问题,本章采用了一种提取刀刃轮廓的图像处理方法。这种方法不仅能够去除刀具表面的纹理特征,还能有效保留刀刃缺陷的关键特征,同时最大限度地减少刀具其他噪声的干扰。提取刀刃轮廓需要经历图像增强、二值化处理、连通域处理、形态学处理以及掩膜处理等过程。

(1) 图像增强: 本文使用的图像增强方法有直方图正规化、伽马变换、全局直方图均衡化以及自适应直方图均衡化,通过不同方法进行图像增强的结果如图 3-8 所示。




图 3-8 不同方法进行图像增强所得结果

(a) 原图; (b) 灰度处理; (c) 直方图正规化处理; (d) 伽马变换; (e) 全局直方图均衡化; (f) 自适应直方图均衡化

Fig. 3-8 Image enhancement results using different methods (a) Original image; (b) Grayscale processing; (c) Histogram normalization; (d) Gamma transformation; (e) Global histogram equalization; (f) Adaptive histogram equalization

由图 3-8 可知,伽马变换使整张图片的像素值处于一种难以区分的状态,不适合分割处理。全局直方图均衡化使刀具表面各处像素值相近,不利于轮廓分割。通过观察以及后续处理发现,直方图正规化得到的图像,刀具图像背景像素值较

统一，刀具像素值与背景区别明显。自适应直方图均衡化所得图像虽然刀具轮廓较为凸显，但是刀具部分边缘像素值与背景融合，不利于后续分割处理。因此，直方图正规化相对于其他方法更适合于作刀刃轮廓的分割处理。

(2) 二值化处理：本文使用的二值化处理方法主要是固定阈值法、自适应阈值法以及 Otsu 阈值法，通过以上三种方法处理后的二值图如图 3-9 所示。对比发现，使用固定阈值法与 Otsu 阈值法进行全局处理时，得到的二值图并不能将刀具表面的花纹轮廓分割出来，因此，对于轮廓复杂的刀具表面还是应该采用自适应阈值法进行局部处理，能够在统一的参数值下较好的呈现不同花纹的刀具轮廓，有利于后续分割处理。




图 3-9 不同二值化处理方法所得结果

(a) 固定阈值法；(b) Otsu 阈值法；(c) 自适应阈值法

Fig. 3-9 Binary processing results using different methods (a) Fixed threshold method; (b) Otsu threshold method; (c) Adaptive threshold method

(3) 连通域处理：该方法的基本原理是将二值化图像中所有白色像素值的连通域作标签，通过设定面积阈值，对标签逐一进行排查，若其连通域面积大于阈值则将像素值设置为 255 即白色，小于阈值则设置为 0 即黑色，其中一个连通域内的像素点个数代表该连通域的面积大小，以此消除二值化图像中的大多数噪声。处理过程如图 3-10 所示。




图 3-10 连通域阈值消除花纹轮廓的处理过程

Fig. 3-10 Connected component thresholding for pattern contour removal process

由于二值化处理后，刀具表面的各个花纹轮廓连通域面积一般小于刀刃轮廓的连通域面积，而且刀刃轮廓可能连接不完整，所以第一次消除噪声时不能将连通域的面积阈值设置过大，否则会造成刀刃轮廓上某些未完全连接的地方被消除，导致刀刃轮廓提取不完整，缺陷特征丢失。本文的阈值设置如式 3-3 所示。

$$x1 = \begin{cases} 255, & \text{area} \geq 4000 \\ 0, & \text{area} < 4000 \end{cases} \quad (3-3)$$

其中， $area$ 表示连通域面积。

由于第一次连通域处理之后，刀具表面内部仍存在面积较大的连通域，该连通域的面积可能大于刀刃轮廓未完全连接的部分连通域，所以需要通过形态学处理将刀刃轮廓连接完整。先用较大的正方形矩阵结构元作膨胀处理，再用较小的正方形矩阵结构元作腐蚀处理，这样可使刀刃轮廓的二值图像完全连接且轮廓均匀。刀刃轮廓连接完整后即可进行第二次连通域处理，将刀具表面内部残余噪声去除，只保留刀具刀刃轮廓边缘的连通域。阈值设置如式 3-4 所示。

$$x2 = \begin{cases} 255, area \geq 30000 \\ 0, area < 30000 \end{cases} \quad (3-4)$$

其中， $area$ 表示连通域面积。

(4) 刀刃轮廓修复处理：通过连通域处理得到刀具刀刃轮廓的二值图后，使用图像掩膜提取方法，将二值图像还原为刀具图片原图中的刀刃轮廓。但是提取后发现某些缺陷在连通域处理过程中未提取完整，刀刃轮廓边缘也有损失，所以需要提取的刀具刀刃轮廓进行修复完善，保证深度学习时能够提取到刀具刀刃的所有特征。




图 3-11 刀刃轮廓修复处理过程

Fig. 3-11 Blade contour repair process

修复处理过程中，通过自适应阈值法对刀具刀刃轮廓图像作二值化处理，可以发现，其二值图轮廓边缘向外扩张了一定距离，之后通过形态学处理中的膨胀处理，将刀刃轮廓边缘二值图填充完整，再通过掩膜处理还原为刀刃轮廓原图，这样就能作较好的修复工作，如图 3-11 所示。

3.3 实验结果与分析

3.3.1 实验环境设置

实验的硬件操作系统是 Windows10, GPU 为 NVIDIA GeForce RTX 3080 Ti, CUDA 版本是 12.6, 使用 3.8 版本的 python 程序, 采用的深度学习框架是 2.10 版本的 tensorflow。深度学习的优化器采用 Adam 优化算法, 它是一种自适应学习率优化算法, 可以通过计算梯度的一阶矩估计和二阶矩估计, 为每个参数设计独立的学习率。通过网格搜索优化算法可以得到较优的参数设置, Adam 学习率

设置为 0.0001，模型训练次数 Epoch 设置为 200，一次训练选取的样本数 Batch size 设置为 4，并且采用五次交叉验证方法进行模型训练。

3.3.2 实验评价指标

实验评价指标是评估模型性能和有效性的关键工具，本文针对刀具缺陷二分类问题，主要采用以下几种常用指标：

(1) 准确率和召回率

准确率 (Accuracy) 是刀具图像正确预测的样本数和总样本数的比值，其公式如 3-5 所示。

$$Acc = \frac{T_P + T_N}{T_P + T_N + F_P + F_N} \quad (3-5)$$

召回率 (Recall) 是刀具图像正确预测的合格类别与真实合格类别的比值，其公式如 3-6 所示。

$$Rec = \frac{T_P}{T_P + F_N} \quad (3-6)$$

其中 T_P 为真合格即合格类别正确预测的样本数， T_N 为真不合格即不合格类别正确预测的样本数， F_P 为假合格即不合格类别错误预测为合格类别的样本数， F_N 为假不合格即合格类别错误预测为不合格类别的样本数。

(2) 损失函数

在深度学习中，损失率 (Loss) 是用来衡量模型预测与真实标签之间差距的指标。在本章刀具缺陷二分类识别的问题中，使用交叉熵损失函数 (categorical_crossentropy) 作为计算损失率的函数。通过 Softmax 激活函数计算出模型输出时刀具合格类与不合格类别的预测概率值，每个概率值介于 0 和 1 之间，确保两类别的概率值和为 1，这就是模型输出时的概率分布。每个真实样本通过独热编码 (one-hot encoding) 表示为 1 和 0 的向量值，其中只有一个元素为 1 表示其为真实样本的概率分布向量，0 则表示其他元素值，这就是真实标签的概率分布。

交叉熵损失函数就是通过计算模型输出的概率分布与真实标签的概率分布之间的交叉熵，来衡量模型的预测结果与实际标签之间的差距。其公式如 3-7 所示。

$$Loss = - \sum_{i=1}^{output\ size} y_i \cdot \log \hat{y}_i \quad (3-7)$$

其中 y_i 表示真实标签的概率分布，其值为 1 或 0； $\hat{y}_i$ 表示模型输出时的概率分布，其值介于 0 和 1 之间，所以当 $y_i = 1$ 时才有结果。

（3）混淆矩阵

混淆矩阵是评估模型预测性能的一种表格形式，能准确反映出不同分类的样本通过模型得到正确预测以及错误预测的样本数量，对于本文中刀具合格与不合格的二分类问题，其混淆矩阵为：

真实值	合格	T_P	F_N
	不合格	F_P	T_N
		合格	不合格
		预测值	

其中每一行表示真实标签，每一列表示模型输出后的预测标签。

通过混淆矩阵可清晰反映出预测过程中哪一部分发生了混淆，也可进一步求解出，在真实样本中，合格类总数为 T_P 与 F_N 之和，不合格类总数为 T_N 与 F_P 之和。根据混淆矩阵中的各值也可求出准确率、召回率等评价指标。

（4）平均精度 AP 以及 mPA

仅用准确率与召回率不能较好地衡量模型的性能，因此引入 AP（Average Precision，平均精度）来直观地表示模型的性能。AP 只能表示测试集中合格类或者不合格类的平均精度，它是 P-R（Precision-Recall）曲线与坐标轴所围成的面积，能够精确反应模型在各类别上的性能。mPA（mean Average Precision）是各类别 AP 值的平均值，能表示模型在测试集中整体上的平均精度，可以较好地衡量模型的综合性能。AP 与 mAP 计算公式如式 3-8 和 3-9 所示。

$$AP = \int_0^1 PR dr \quad (3-8)$$

$$mAP = \frac{AP_0 + AP_1}{2} \quad (3-9)$$

3.3.3 实验结果对比与分析

模型通过 CBAM 注意力模块对卷积层输出的特征图进行处理，其可视化结果如图 3-12 所示。可以观察到随着模型层次的增加，刀具特征图逐渐模糊，造成特征信息的大量丢失，引入注意力模块后，深层次特征信息更容易被注意到。对比深层网络 block14_2 在引入注意力模块前后的特征图可发现，模型在特征提取方面表现得更加集中。




图 3-12 各层加入 CBAM 注意力模块前后的特征图对比

Fig. 3-12 Comparison of feature maps before and after adding CBAM attention module to each layer

表 3-2 不同处理方式对比结果

Table 3-2 Comparison of different processing methods

序号	处理方式	ACC	Recall	Loss
模型 1	简单图像预处理	0.8966	0.8125	0.2975
模型 2	刀刃轮廓提取处理	0.9310	0.8750	0.2311
模型 3	X-CBAM	0.9655	0.9375	0.1263




图 3-13 混淆矩阵图

(a) 简单图像预处理；(b) 刀刃轮廓提取处理；(c) X-CBAM 模型

Fig. 3-13 Confusion matrix diagram (a) Simple image preprocessing; (b) Blade contour extraction process; (c) X-CBAM model

刀具原图像在经过刀刃轮廓提取后，还需对其进行灰度处理和对比度增强的简单图像预处理，提高刀具刀刃缺陷轮廓与其他区域的对比度，然后作为模型输入进行训练。如表 3-2 所示，模型 1 与模型 2 采用未改进的 Xception 模型作训练模型，分别将简单图像预处理的数据集和经过刀刃轮廓提取的数据集输入模型。模型 3 则将经过刀刃轮廓提取的图像数据集输入改进后的 Xception 模型进行训

练。三种不同训练方法下所得结果对比如表 3-2 所示，混淆矩阵如图 3-13 所示。

通过表 3-2 可以看出，使用 Xception 预训练模型作特征提取器时，经刀刃轮廓提取处理后，刀具图像数据集的训练准确率和召回率分别提高 3.44%、6.25%，损失率下降 0.0664。进一步引入 CBAM 注意力模块并结合多层次特征融合后，准确率和召回率分别再次提高了 3.45%、6.25%，损失率下降 0.1048。由此可见，圆形车刀刀具图像经过刀刃轮廓提取处理，可以更加突出刀刃缺陷特征，提升训练精度。融入多个 CBAM 注意力模块后，模型由浅层到深层网络对缺陷特征的关注度均上升，将浅层特征与深层特征进行融合后，使模型的泛化能力增强，提高模型训练准确率。




图 3-14 预测结果

Fig. 3-14 Prediction results of tool images using different image processing methods

训练完成后，使用三种不同的处理方式对刀具图像进行预测，其预测结果如图 3-14 所示，表 3-3 为图 3-14 中每一张图像对应的预测概率，其中 U 表示不合格，Q 表示合格。

表 3-3 刀具图像在不同图像处理方式下的预测概率

Table 3-3 Prediction probabilities of tool images under different image processing methods							
	图 1	图 2	图 3	图 4	图 5	图 6	图 7
X-	0.999	0.977	0.999	0.603	0.931	0.999	1.000
轮廓处	0.999	0.844	0.999	0.562	0.901	0.998	0.999
简单图 像预处	0.924 (U)	0.840 (U)	0.874 (U)	0.860 (U)	0.894 (U)	0.919 (Q)	0.972 (Q)

由图 3-14 以及表 3-3 可知，使用表 3-1 中模型 1 的简单图像预处理方法进行刀具图像预测时，由于刀具表面轮廓的影响，模型将图 3-14 中第五张合格类无缺陷图片预测为不合格类，并将第六张不合格类有缺陷图片预测为合格类。在经过模型 2 的刀刃轮廓提取处理后，再次进行刀具图像预测时，虽然 Xception 模型能区分缺陷较为明显的前三张图片以及最后一张合格类图片，但是对于缺陷较

小的第四张图片不能准确预测，有 56.2% 的概率将其区分为合格类。采用 X-CBAM 模型对经过刀刃轮廓提取的图像数据集训练后，在进行预测时，可以发现准确率提高，对于第四张小缺陷图片也能有 60.3% 的概率预测为不合格类，与预测效果相对较好。




图 3-15 训练集和测试集的准确率

Fig. 3-15 Training set and test set accuracy




图 3-16 训练集和测试集的损失率

Fig. 3-16 Training set and test set loss rate

采用 X-CBAM 模型对刀具图像进行训练，迭代次数为 200 次，训练后准确率和损失的变化如图 3-15、图 3-16 所示。观察发现，训练集的准确率与召回率整体呈现上升趋势，测试集的准确率与召回率在迭代次数为 100 轮之后围绕概率为 0.9655 的水平线上下波动，波动起伏较小，呈现收敛状态。训练集和测试集的损失率整体呈现下降趋势，训练后测试集损失率起伏不大，最后均落在 0.1 到 0.2 区间中，训练效果满足要求。




图 3-17 不同模型训练后的 P-R 曲线

Fig. 3-17 Precision-Recall curves of different models after training

本文将经过刀刀轮廓提取处理后的图像数据集输入不同模型进行训练，并对比观察 X-CBAM 模型的学习能力。主要实验模型有残差模型 ResNet50、简单卷积的 InceptionV3 模型、Xception 模型以及 X-CBAM 模型。不合格类与合格类刀具图像在不同模型训练后的 P-R 曲线如图 3-17 所示。通过对不合格类和合格类分别计算 AP 值，并进一步计算综合平均精度 mPA 值，可以全面评估各模型的表现，具体结果汇总如图 3-18 所示。对比发现，不合格类在 Xception 模型训练中 AP 值为 0.9439，结果较好；合格类在 X-CBAM 模型中 AP 值最高，为 0.9576；综合平均精度 mPA 在 X-CBAM 模型中训练所得值为 0.9494，对比其他模型更为突出。




图 3-18 不同模型训练后计算所得 AP 值与 mPA 值

Fig. 3-18 AP and mPA values calculated after training different models

X-CBAM 模型与其他几种模型对刀具图像训练后的最终准确率与损失率结果对比如表 3-4 所示。如图 3-19、图 3-20 所示，对比不同模型在测试集上的准确率与损失率曲线后发现，本文模型在进行刀具缺陷图像二分类训练时，表现出了更高的准确率和更低的损失率，能够提升分类性能，减少误差。

不同模型训练后的对比结果说明，同时具有深度可分离卷积以及残差结构的 Xception 模型相比以往模型具有更为强大的特征提取能力，在进行刀具图像二分

类时，能够表现出更好的泛化性能。在引入 CBAM 注意力模块并结合多层次特征融合后，Xception 模型得到进一步优化，能够更加准确的进行刀具图像二分类。

表 3-4 不同模型之间的准确率与损失率结果对比

Table 3-4 Comparison of accuracy and loss rate results between different odels

模型名称	训练集	训练集	测试集	测试集
	准确率	损失率	准确率	损失率
ResNet50	0.7105	1.133	0.7931	0.6109
InceptionV3	0.9135	0.1923	0.8621	0.4428
Xception	0.8947	0.2532	0.9310	0.2311
X-CBAM	0.9211	0.1758	0.9655	0.1263




图 3-19 不同模型的准确率曲线图

Fig. 3-19 Accuracy curves of different models




图 3-20 不同模型的损失率曲线图

Fig. 3-20 Loss curves of different models




图 3-21 刀具图像在不同模型下的预测结果

Fig. 3-21 Prediction results of tool images under different models

最后，将不同模型的训练结果用于刀具图像预测，预测结果对比如图 3-21 所示，对应的预测概率如表 3-5 所示。可以发现，ResNet50 模型将第一张和第六张两种不合格类缺陷明显的刀具图像判断为了合格类刀具，而且概率分别为 57.1% 和 97.2%。InceptionV3 模型进行预测时，出现了与 Xception 模型预测时相同的情况，虽然能区分缺陷较为明显的前三张图片以及最后一张合格类图片，但是对于缺陷较小的第四张图片仍不能准确区分，有 63.5% 的概率将其区分为合格类，而 Xception 有 56.2% 的误判概率，而且在准确区分的图片中，其分类准确率也低于 Xception 模型与 X-CBAM 模型。X-CBAM 模型在预测过程中能够较为准确的区分合格类与不合格类刀具，而且整体的预测精度相对其他模型更好，对于第四张缺陷较小的刀具图片也能有 60.3% 的准确率将其区分为不合格类。

表 3-5 刀具图像在不同模型下的预测概率

Table 3-5 Prediction probabilities of tool images under different models

	图 1	图 2	图 3	图 4	图 5	图 6	图 7
X-CBAM	0.999	0.977	0.999	0.603	0.931	0.999	1.000
Xception	0.999	0.844	0.999	0.562	0.901	0.998	0.999
InceptionV3	0.959	0.965	0.912	0.635	0.699	0.999	0.999
ResNet50	0.571	0.993	0.712	0.883	0.913	0.972	0.999

3.4 本章小结

本章提出图像预处理方法以及训练模型，对圆形机夹式车刀刀刀缺陷图像数据集进行二分类时，准确率可达 96.55%，能够满足判断刀具是否合格的检测要

求，具体结论如下：

1) 针对刀具表面轮廓复杂，影响刀刃缺陷检测的问题，本章通过二值化处理以及根据连通域面积去除噪声的图像处理方法，成功分割出圆形车刀的外围刀刃轮廓部分，使刀刃缺陷更加突出，有利于后续的训练检测。

2) Xception 模型基于残差网络与深度可分离卷积构建特征提取网络不仅提高了模型泛化能力和鲁棒性，而且减少了参数量、运算量，相对其前身模型 InceptionV3 以及残差网络 ResNet50 更适用于作圆形机夹式车刀刀刃缺陷检测的特征提取网络架构。

3) 引入 CBAM 注意力模块并结合多层次特征融合后，Xception 模型可以有效地将浅层信息与深层信息整合在一起，提高模型对刀具图像数据的特征理解能力和处理能力，从而提升模型性能和准确性。

4) 相对其他模型，X-CBAM模型在对刀刃缺陷图像进行训练后能够得到更高的综合平均精度mPA，为0.9494。进行刀具图片预测时，X-CBAM模型能够更加精准的判断出刀具是否合格，对小缺陷刀具图片也能进行较为准确的分类，说明该模型具有更强的分类能力。

4. 基于多任务学习的刀具缺陷分

缺陷分割是圆形机夹式车刀缺陷的又一种检测方法,但是由于单任务分割模型的局限性,并不能有效分割刀刃部分的细小缺陷特征。因此,为了实现剥落缺陷的高精度分割,本章基于分类任务有助于提升分割任务对图像理解的理念,提出了一种以改进 U-Net 语义分割模型为基准的多任务学习模型。将 U-Net 模型的编码器部分替换为 Xception 特征提取网络以增强复杂背景下的信息捕捉能力,共享该特征层后构建两任务分支,分类任务以第三章提出的多层特征融合模块进行改进,分割任务的解码器部分使用 FPN 架构与 AGs 模块结合的横向连接结构,增强对特定尺度上缺陷特征的提取能力

4.1 多任务网络模型 Multi-UF-Xception 设计

结合第二章有关多任务学习的理论知识,本章主要采用硬参数共享的多任务学习模型,将分割与分类联系起来。在训练过程中,分类任务能够捕捉全局信息和高级语义特征,通过共享特征以及提供额外的监督信号,分割任务能够更好地理解刀具图像数据的整体结构,从而提升分割任务的鲁棒性和泛化性能,减少过拟合,增强模型的分割能力。

考虑到圆形车刀图像中刀刃剥落缺陷面积差异大、位置分布多样化的问题,网络需要足够的感受野和强大的空间多尺度处理能力,所以使用 MobileNet 等轻量化网络不适合于作圆形机夹式车刀刀刃缺陷的分割提取。因此,选取同样具有深度可分离卷积、特征提取能力更强的 Xception 网络作特征提取网络,并对 U-Net 模型进行改进,在此基础上融合 FPN 网络与注意力机制,进而构建分割与分类的多任务学习网络模型。

4.1.1 改进 U-Net 网络描述

U-Net 是一种卷积神经网络架构,最初由 Ronneberger 等人在 2015 年提出,主要用于生物医学图像分割任务,其因为独特的“U”形结构而得名,该结构能够有效地捕捉图像中的空间信息,并在不同尺度上进行特征提取和融合。实际应用中常常对其进行结构上或非结构上的改进^[86],增强模型性能。

U-Net 的核心架构为编码器和解码器两个部分,而且作为分割模型,其完全舍弃了用于分类输出的全连接层,仅通过卷积层进行搭建,同时拥有下采样与上采样的卷积结构,如图 4-1 所示。编码器通过卷积层与池化层的交替堆叠实现特征下采样,通常包含 5 个下采样层级,每个层级通过多次卷积操作提取局部特征,随后通过最大池化层(如 2×2 窗口)将空间分辨率减半,逐步压缩空间维度以增强特征表达的抽象性。解码器部分是通过多个转置卷积形成的上采样过程,该部分通过转置卷积能够将前一层的特征图分辨率提高。从编码器部分第五个

block 的输出开始进行上采样，经过一次转置卷积后会输出与编码器部分第四个 block 的输出特征相同分辨率的特征图，同时通过跳跃连接将来自编码器相应层级的特征图拼接到当前特征图上，可以将低级别的细节信息传递给高级别的特征表示，然后再使用卷积和 Rule 函数激活，之后再进行转置卷积。重复上述步骤，编码器就与解码器前四个 block 形成了一个对称的结构，最后使用 1×1 卷积减少通道数，输出分割掩码。




图 4-1 U-Net 网络结构图

Fig. 4-1 U-Net network structure diagram

针对圆形车刀刀刃剥落缺陷大小不一、形状复杂的问题，改进 U-Net 模型使用 Xception 网络下采样部分替代原 U-Net 网络编码器部分，增强对多尺度特征的提取能力，并选用其中的 4 个层级的输出进行跨层连接，同时在解码器部分转置卷积也相应做出改变。改进 U-Net 网络结构如图 4-2 所示。




图 4-2 改进 U-Net 网络结构图

Fig. 4-2 Improved U-Net network structure diagram

4.1.2 FPN 结构描述

特征金字塔是识别系统中检测不同尺度特征的主要工具,但是由于特征化图像金字塔计算速度慢、不能实现端到端的训练等缺点, Lin 等^[87]在 2016 年提出

了 FPN (Feature Pyramid Network) 网络结构, 利用深层卷积神经网络逐层计算特征层次, 从而得到不同层的多尺度特征图。对于圆形机夹式车刀刀刃上的缺陷, 由于其尺寸大小差异较大, 使用特征金字塔网络能够有效提取不同尺度上的缺陷特征。通过融合高低层次的特征信息, 这种方法不仅能够处理大尺寸缺陷, 还能显著增强对小目标缺陷的检测能力。

FPN 架构拥有自下而上与自上而下的路径, 通过横向连接将低分辨率、语义强的特征与高分辨率、语义弱的特征相结合, 最后形成一个特征金字塔网络, 如图 4-3 所示。这一过程使得每个层级的特征图均具备高语义表达能力, 同时支持从单输入图像快速构建多尺度表示。相较于传统方法需通过缩放图像构建金字塔的高计算开销, FPN 通过网络内部的特征复用与优化, 既保持了多尺度特征的表征能力, 又显著降低了计算复杂度。这种设计使其成为目标检测、语义分割等任务中高效且轻量化的多尺度特征提取方案。




图 4-3 FPN 网络结构图

Fig. 4-3 FPN network structure diagram

FPN 具体网络结构与 U-Net 网络类似, 首先使用一个深层卷积网络作骨干网络实现自下而上的下采样过程, 然后自顶向下对深层特征作上采样处理, 并且均有横向连接结构。FPN 网络中的横向连接是指骨干网络的浅层特征在经过一个 1×1 的卷积后与来自上采样后的深层特征图进行逐元素相加, 实现语义信息与空间细节的融合, 目的是将深层的高语义特征传递至较低层级的特征图, 从而增强浅层特征的语义表达能力, 最后对融合后的特征进行 3×3 的卷积操作, 用来消除由上采样带来的混叠效应, 并且调整通道数, 输出特征图。

FPN 对多尺度特征图都进行了预测，主要用于目标检测，而 U-Net 网络只对最后一层网络进行分割预测，所以两者有较大区别，但是将 FPN 架构置于 U-Net 网络的解码器部分，能够帮助模型更好地理解编码器传递的特征信息。Sun 等^[88]通过在 U-Net 网络中加入 FPN 架构，提出了一种基于改进特征金字塔网络的卷积神经网络脑肿瘤图像分割方法，该方法能够提高模型对不同尺度的适应性，同时提升网络整合多尺度信息的能力，对脑肿瘤的分割准确率高达 99.1%。同样将此方法用于本文刀刃缺陷分割中，可以丰富提取到的缺陷特征信息，提升模型分割能力。

4.1.3 Attention Gates (AGs) 注意门机制

AGs 模块是为了解决医学图像任务而提出的，AGs 模块的提出解决了因靶器官形状大小差异而使用级联卷积导致的模型复杂、参数量大以及重复提取低级特征等问题^[89]。该模块一般用于 U-Net 网络的跳跃连接部分，在对刀具刀刃缺陷特征信息进行多尺度特征融合的过程中，AGs 模块能够对来自解码器部分的特征信息进行解析，并且决定哪些编码器的特征能够传递给下一层。这不仅帮助模型更好地聚焦于缺陷特征，还能忽略背景噪声，从而提高分割边界和内部区域的准确性。

AGs 模块主要用在 U-Net 网络中编码器到解码器的跳跃连接过程中，如图 4-4 所示，该模块的输入分别是来自跳跃连接对应编码器部分的下采样层特征图 g 以及跳跃连接对应解码器部分的前一层特征图 x ，之后将两输入在通道方向上进行线性变换得到 W_g 与 W_x ，一般将两输入的通道数调整为相同大小，并且不改变两输入的空间维度（宽和高）。使用 Add 函数对 W_g 和 W_x 进行逐元素相加，相加之前需要将 W_g 进行上采样，确保 W_g 与 W_x 形状相同，再经过 Relu 函数后又通过线性变换将其转换为一维通道，之后选择 Sigmoid 激活函数将注意力系数 δ 归一化，使得训练 AGs 参数时能更好收敛，最后使用卷积函数将通道数还原为与 x 输入一样的通道数，空间维度保持不变，得到最终的注意力系数 α ，将 α 与 x 进行逐元素相乘得到一个加权特征图，这样就完成了 AGs 模块对重要特征的提取。




图 4-4 AGs 模块网络结构图

Fig. 4-4 AGs module network structure diagram

4.1.4 Multi-UF-Xception 整体网络结构

对于缺陷检测中分割与分类的研究,大多数学者使用的模型都是传统的单任务模型,两个任务之间彼此独立,均只有一个输出,而使用多任务模型将分割与分类关联起来,能够使两个任务提取的特征被共同使用,使模型的泛化能力大大增强。该方法常用于医学研究中,Zhou 等人^[90]提出一种新的多任务学习框架,用于 3D 自动乳腺超声图像中肿瘤的联合分割和分类,同时采用迭代训练策略细化特征图,实验证明该方法优于单任务学习方法。RHe 等人^[91]结合边缘预测、分割和分类三个检测任务,构建了皮肤病检测多任务学习网络模型 MTL-CNN,同时引入边缘信息增强(EIE)模块与病变区域提取(LAE)模块,最后采用三阶段训练策略对数据集进行训练,提升了对皮肤病特征的分类与分割性能。实验研究结果表明,多任务学习模型能够在医学分割和分类中表现出较好的性能。因此,在本文中,同样也能够将刀刃缺陷的分类与刀刃缺陷的分割联系起来,使用多任务模型进行训练学习同样能够提升模型对刀刃缺陷的分割能力。

U-Net 网络结构虽然具有特征提取、跨层连接以及特征融合的完美机制,但是直接使用 U-Net 网络进行刀具缺陷的分类与分割多任务学习并不可取。所以为了增强模型的特征提取能力,并提升刀刃缺陷的分割精度,本文将网络分为两部分:共享特征层与任务特定层。

共享特征层即 U-Net 网络编码器部分即特征提取网络部分,本文中去除 Xception 全连接层并保留进行下采样的卷积神经网络部分,用于替换 U-Net 网络编码器部分以作进行特征提取的共享特征层,得到单任务分割模型(XU-Net)。

任务特定层即分割与分类两个任务的网络结构。首先,本文选取共享特征层即 Xception 的 block1_1 卷积层以及 block4_1、block7_1、block10_1 和 block14_2 深度可分离卷积层各自的输出作为不同层次的输出特征,用以满足 U-Net 网络与 FPN 网络的基本结构;其次,在实现 U-Net 网络编码器特征与解码器特征融合之前,先将共享特征层部分作为 FPN 结构的骨干网络实现不同层级的特征信息融合并生成对应层级的 4 个特征输出;然后,再将 4 个特征输出通过横向连接与解码器中对应层级的特征进行融合,横向连接过程中添加 AGs 注意力模块增强特征提取能力;最后,自下而上完成上采样以及不同层级的特征融合,并对解码器部分最后一层网络进行分割预测,这样就实现了改进 U-Net 网络对刀具刀刃缺陷进行分割的任务。进行分类任务时,为了模型能够关注到刀具图片上的小目标缺陷特征,使 Xception 模型与 CBAM 注意力模块融合在一起,在 Xception 的 block1_1 的卷积层以及 block4_1、block7_1、block10_1 和 block14_2 深度可分离卷积层各自的输出后增添 CABM 注意力模块,经注意力模块输出后,增添通道数为 256 的卷积层并且作下采样处理,使五个模块输出的特征图维数相同以便作

合并处理，这样可以将深层与浅层信息整合在一起实现多尺度信息融合，从而提高模型对输入数据的理解和处理能力，之后添加全连接层实现分类任务。

通过上述对网络结构的解释可知，本文以 Xception 网络为基线模型对 U-Net 模型进行改进，使用硬参数共享的方式，并且在此基础上融合 FPN 网络，进而构建了进行刀具缺陷分割与分类的多任务学习模型（Multi-UF-Xception），网络结构如 4-5 所示。




图 4-5 Multi-UF-Xception 模型网络结构图

Fig. 4-5 Multi-UF-Xception model network structure diagram
损失函数

在圆形机夹式车刀刀刃的缺陷分割实验中，使用的是分类与分割相结合的多任务学习网络，所以使用的损失函数也应该是两个。如果没有为两个损失函数设置特定的权重参数，则默认权重参数均为 1，即直接将两个损失函数简单相加，作为整个多任务学习网络的总损失函数，但是这样做可能会造成损失值较大的任务主导优化过程、一个任务出现过拟合而另一个任务出现欠拟合以及任务之间收敛速度不平衡等问题^[92]。因此，为了解决上述问题，两个损失函数分别设置了特定的权重参数 α 、 β ，并且在训练过程中动态调整任务权重。由于本文分割实验中需要提高模型分割精度，所以动态调整过程中，在保证分类任务不出现过拟合或欠拟合的情况下，将分割任务的损失权重调整的比分类任务的损失权重更大，使分割任务的重要性大于分类任务，实现分割任务的持续优化。损失函数公式如式 4-1 所示，其中 L_{all} 为总损失函数， L_s 为分割任务损失函数， L_c 为分类任务损失函数。

$$L_{all} = \alpha L_s + \beta L_c \quad (4-1)$$

在动态调整权重比例时，设置初始权重比例为 1: 1，即 $\alpha=1$ 、 $\beta=1$ 。之后通过分类损失的变化进行动态调整，如果当前 Epoch 的分类任务损失小于模型训练过程中记录的最小损失则不进行调整，否则在超过“耐心值”（patience）的等待时间后分割权重增加 0.02，分类权重减少 0.02，重复此过程，同时需要保证分割权重最大为 3，分类权重最小为 0.1。其中，“耐心值”指的是在分类任务损失

未改善的情况下，允许等待的最大 Epoch 次数。调整公式如 4-2 所示。

$$\begin{aligned}\alpha_{_new} &= \min(3, \alpha + 0.02) \\ \beta_{_new} &= \max(0.1, \beta - 0.02)\end{aligned}\quad (4-2)$$

4.2 实验

4.2.1 数据处理

采集到刀具图像数据共有 180 张，其中合格类有 98 张，不合格类有 82 张。在刀具缺陷分割实验中，需要进行分割的主要是不合格类中的刀刃剥落类缺陷，所以需要对这类缺陷进行标注。

进行标注时，一般采用 Labelme 标注工具，只需标注不合格类中的剥落类缺陷，并以中文拼音命名为“quexian”，标注后生成的 json 文件通过 python 程序被转化为掩码标签（Mask 标签）；对于合格类图片，不需要进行缺陷标注，直接使用二值化处理将其转化为像素值只有 0 的图片，作为合格类的掩码标签。标注及转化过程如图 4-6 所示。




图 4-6 掩码标签制作

Fig. 4-6 Mask label creation

由于分割实验中使用的是多任务学习网络，需要保证分割与分类任务的图像输入一致，所以不需要作刀刃轮廓提取的图像处理，其分类任务中合格类与不合格类的输入标签也转化为 0 和 1。同时，两类任务的训练集与测试集也需保持一致，所以在使用 train_test_split 函数划分数据集时，分割任务与分类任务需要设置同一随机种子，并且以图像数据的 80% 为训练集，20% 为测试集。

4.2.2 实验环境设置

实验的硬件操作系统是 Windows10，GPU 为 NVIDIA GeForce RTX 3080 Ti，CUDA 版本是 12.6，使用 3.8 版本的 python 程序，采用的深度学习框架是 2.10 版本的 tensorflow。采用 Adam 优化算法，通过多项式学习率衰减动态调整学习率 $l_r^{[93]}$ ，学习率最大为 0.001，最小为 0.000001，衰减步数为 50×72 ，衰减幂次为 2， $current_step$ 代表当前训练步数，所得多项式学习率衰减公式如式 4-3 所示。模型训练次数 Epoch 设置为 200，一次训练选取的样本数 batch size 设置为 4。

$$l_r = 0.000001 + (0.001 - 0.000001) \times (1 - \frac{\text{current_step}}{50 \times 72})^2 \quad (4-3)$$

4.2.3 实验评价标准

在结合分类与分割进行多任务学习时，需要同时评估两个分支任务，最终的评估结果能够反映该模型的好坏。对于分类任务，使用如第四章所述的准确率进行评估；对于分割任务，使用均交并比（MIoU）进行评估。

MIoU 是用于评价图像分割模型性能的一个重要指标，是通过计算每一个分割类别的交并比（IoU）值，然后求取均值得到的，如式 4-4 所示。IoU 表示的是图像分割中分割类别预测后所占区域与真实标签所占区域的重叠比例。将预测后的分割区域表示为 P，真实标签的分割区域表示为 G，那么 IoU 可以表示为 P、G 的交集与 P、G 并集的比值，如式 4-5 所示。

$$\text{MIoU} = \frac{1}{n} \sum_i^n \text{IoU}_i \quad (4-4)$$

$$\text{IoU} = \frac{|P \cap G|}{|P \cup G|} \quad (4-5)$$

由公式 4-5 可知，IoU 越接近 1 则表示该类别的分割精度越高，越接近 0 则表示重叠区域很少，模型分割精度低。计算出所有分割类别的 IoU 值之后，求取平均值得到 MIoU，就能够全面反映模型的分割性能。

由于多任务模型在训练过程中对分类任务与分割任务的标签均进行了独热编码处理，所以损失函数均采用如第四章所述的交叉熵损失函数进行损失评估。

4.2.4 实验结果与分析

多任务学习的缺陷分割模型通过 FPN 架构以及 AGs 注意力机制对编码器卷积层输出的特征图进行处理，其可视化结果的前后对比如图 4-7 所示。通过可视化结果图可以观察到，通过在分割模型横向连接过程中依次引入 FPN 架构以及 AGs 模块，能够使编码器传递给解码器的不同通道特征信息更加集中，有效地减少了背景噪声的干扰，从而提高刀具缺陷特征信息提取的准确性。

为了验证本章模型优化后对圆形机夹式车刀刀刃剥落缺陷分割精度提升的有效性，需要进行消融实验来评估模型的整体性能，同时消融实验中的每个模型重复训练 7 次，并取平均值作为训练结果。

分割任务进行消融实验时，使用 XU-Net 作为基线模型，进行一系列销蚀操作。对 XU-Net 模型、增加分类任务的 XU-Net 多任务模型（Multi-XU-Net）、带有 AGs 模块的 Multi-XU-Net 模型（Multi-XU-Net+AGs）、融合 FPN 架构的 Multi-XU-Net 模型（Multi-XU-Net+FPN）以及 Multi-UF-Xception 五个模型进行消融实

验，实验结果如表 4-1 所示。




图 4-7 通道特征图可视化结果对比

Fig. 4-7 Comparison of channel feature map visualization results

由于本章主要研究圆形机夹式车刀刀刃剥落缺陷的分割精度，所以通过表 4-1 中各模型分割任务的 seg-miou 值对比可知，增加分类任务的多任务分割模型 Multi-XU-Net 相对于单任务分割模型 XU-Net 更有利于进行缺陷分割，MIoU 值提升较大；多任务模型 Multi-XU-Net 在分割任务中添加 AGs 模块或 FPN 架构后，分割精度均会得到提升，最终将 AGs 模块与 FPN 架构同时融入模型后，MIoU 值提高 0.0308。

表 4-1 基于单任务模型 XU-Net 的消融实验结果对比

模型名称	cla-loss	seg-loss	cla-acc	seg-miou
XU-Net	/	0.0057	/	0.6062
Multi-XU-Net	0.3370	0.0026	0.8195	0.8297
Multi-XU-Net+AGs	0.3410	0.0039	0.7917	0.8371
Multi-XU-Net+FPN	0.3938	0.0022	0.7818	0.8540
Multi-UF-Xception	0.4022	0.0024	0.7938	0.8605

如图 4-8 所示，对比单任务分割模型 XU-Net 与多任务模型 Multi-UF-Xception 的 Loss 曲线，可以发现，多任务分割模型的损失值明显小于单任务分割模型，说明多任务模型更有效地学习到数据中的特征，从而提高了分割精度。




图 4-8 单任务分割与多任务分割的损失率曲线对比

Fig. 4-8 Comparison of loss curves between single-task segmentation and multi-task segmentation

多任务学习模型中分割任务完成消融实验后，可以检测 Multi-UF-Xception 模型中分类任务中多尺度信息融合与 CBAM 模块对分割精度的影响，将 Multi-UF-Xception 模型分类任务减少多尺度信息融合的模型（Multi-UF-Xception-N）、分类任务多尺度信息融合时不添加 CBAM 模块的 Multi-UF-Xception 模型（Multi-UF-Xception-C）以及 Multi-UF-Xception 模型进行对比，实验结果如表 4-2 所示。

表 4-2 分类任务消融实验结果对比

Table 4-2 Classification task ablation experiment results comparison

模型名称	cla-loss	seg-loss	cla-acc	seg-miou
Multi-UF-Xception	0.4022	0.0024	0.7938	0.8605
Multi-UF-Xception-N	0.3926	0.0024	0.7868	0.8506
Multi-UF-Xception-C	0.4012	0.0023	0.8215	0.8543

实验结果表明，分类任务不进行多尺度信息融合并添加 CBAM 模块，分割任务的分割精度会有所下降，这是因为分类任务进行优化后，捕捉全局信息和高级语义特征的能力更强，通过共享底层网络层，分割任务从分类任务中受益，获得更鲁棒的特征表示，有利于模型进行分割。

通过消融实验可以得到上述 7 个模型对剥落缺陷类别进行分割后的 IoU 值，如图 4-9 所示。可以发现，使用多任务学习模型进行缺陷分割的精度相较单任务学习模型有明显提升，模型 Multi-UF-Xception 对剥落缺陷进行分割的 IoU 值为

0.7216，在消融实验中表现出更好的分割性能。




图 4-9 不同模型的 IoU 值对比

Fig. 4-9 Comparison of IoU values across different models

最后，在训练过程中，将 Multi-UF-Xception 模型分类与分割任务进行如 4.2 节的损失权重参数调整，能够进一步发挥模型的分割能力，使 MIoU 值提升到 0.8626，如表 4-3 所示。

表 4-3 权重调整前后结果对比

Table 4-3 Comparison of results before and after weight adjustment

模型名称	cla-loss	seg-loss	cla-acc	seg-miou
Multi-UF-Xception	0.4022	0.0024	0.7938	0.8605
Multi-UF-Xception+loss	0.3877	0.0025	0.7979	0.8626

通过实验数据可以看出，单任务模型进行分割的能力远小于多任务模型，分类任务的信息捕捉能力能够帮助分割任务更加准确的确认特征信息，通过分割任务与分类任务的进一步改进，本章提出的 Multi-UF-Xception 多任务模型能够更加准确地分割圆形机夹式车刀刃刃剥落缺陷，在经过权重比例调整后，分割能力进一步提升，能够更加精确地提取缺陷特征。

将消融实验中的模型用于对圆形机夹式车刀刃刃缺陷进行分割预测，如图 4-10 的可视化结果所示，与原图的刀刃缺陷 Mask 图作对比，多任务模型 Multi-XU-Net 添加 AGs 模块后，对缺陷特征的提取能力更强；进一步添加 FPN 架构，

构建 Multi-UF-Xception 模型后，对细小缺陷的分割能力进一步增强；经过损失权重调整后，Multi-UF-Xception 模型能够分割圆形车刀中对比度不明显的缺陷特征。单任务分割模型 XU-Net 进行预测时，由于其分割精度过低，预测所得图片并不能分割缺陷，所以此处并未做对比。因此，添加分类任务的多任务学习模型能够提升分割任务的分割能力，分割任务解码部分构建 FPN 架构并添加 AGs 模块更有利于对刀刃缺陷特征的提取，而且 Multi-UF-Xception 模型的分割性能和分类和分割的损失权重有关，合理调整损失权重能够提升分割能力。




图 4-10 消融实验中模型对刀刃缺陷进行分割预测的结果对比

Fig. 4-10 Comparison of blade defect segmentation prediction results in ablation experiments

4.3 本章小结

本章提出多任务学习模型 Multi-UF-Xception 对圆形机夹式车刀刀刃的剥落缺陷进行分割的方法，模型训练后的 MIoU 值可达 0.8626，能够较为准确的分割刀刃上的剥落缺陷，具体结论如下：

1) 针对圆形机夹式车刀的刀刃剥落缺陷大小差异大、位置分布复杂问题，将 U-Net 模型的编码器部分替换为 Xception 网络的特征提取部分，采用深度可分离卷积可以增强对刀刃缺陷特征的提取能力。

2) 针对单任务分割模型对刀刃缺陷分割能力不足的问题，将分类任务与分割任务关联起来形成多任务学习模型，通过学习并共享两任务之间潜在的有用信

息，能够较大幅度地提升模型的分割性能。

3) 为了进一步改进多任务学习模型，本文将 AGs 模块与 FPN 架构添加到分割任务中的解码器部分，将分类任务进行多层次特征融合并添加 CBAM 模块，以此提升模型捕捉有用信息的能力，进而提升模型的分割能力。

4) 进行训练时，通过动态调整多任务学习模型 Multi-UF-Xception 的分割与分类任务的损失权重比例，能够进一步提升模型的分割性能，而且对刀刃上细小缺陷的分割预测能力更强。

5. 刀具缺陷检测平台设计

在当前的机械加工生产实践中,及时准确地判断刀具是否合格是确保生产效率和产品质量的关键。将高精度的刀具缺陷检测算法与机器视觉技术相结合,可以实现对刀具缺陷的快速精准识别与分类。为此,本文基于前两章提出的圆形机夹式车刀刀刀缺陷分类与分割算法,开发了一个刀具缺陷检测平台。该平台旨在探索这些算法的实际应用方法,同时满足实际生产的严格要求,从而实现刀具刀刀缺陷的智能化检测,减少人工目测带来的局限性和误差。

5.1 平台功能概述

在机械加工过程中,刀具的刀刃部分可能会出现剥落、切削刃微崩等缺陷,这些问题会直接影响加工精度和产品性能。为了确保产品质量,在批量生产中必须及时发现并处理这些刀具缺陷。然而,传统的人工目测检测效率低下且主观性强,容易受到多种因素干扰,导致识别准确率下降。为此,采用图像识别技术成为一种有效的替代方案。

图像识别是一种利用计算机对图像进行处理、分析和理解,从而识别出各种不同模式的目标和对象的技术^[94]。如何进行高准确率的图像识别是提高生产效率与产品质量的关键所在。为此,本章结合深度学习中的卷积神经网络训练方法,调用训练好的模型架构和权重,建立了一套适用于圆形机夹式车刀刀刀缺陷分类与分割的检测系统。依据该方法,搭建出了相应的刀具缺陷检测平台。通过该平台,可以选择合适的预训练模型与优化算法,调整相关参数可提高训练后的准确率,也可以观察到模型训练的运行过程、准确率和损失率随迭代次数的变化情况以及混淆矩阵的分布情况;通过调用训练好的模型架构和模型权重可以实现对本地图具缺陷图片的识别,还可以连接摄像头实现对刀具缺陷图像的实时识别。该软件为实现刀具缺陷的高精度识别提供了强有力的工具,有利于提高刀具缺陷识别效率,应用于机械加工生产中,可提高生产效率,降低生产成本。

5.2 平台架构及设计

刀具缺陷检测平台主要包含以下几个部分:用户登录模块、模型训练模块、图像检测模块以及结果展示模块。因此本文设计的刀具缺陷识别系统整体架构可分为:用户登录、模型训练、分类与分割预测、结果展示与保存,其中模型训练要用于展示如何利用预训练模型对采集的刀具缺陷图片进行训练,并支持参数调整与优化;分类与分割预测主要是调用本文提出的模型算法,实现对刀具的整体分类以及对刀刃缺陷的精确分割,平台架构如图 5-1 所示。

刀具缺陷检测平台的设计主要是通过以下几个步骤实现的:

1、开发环境配置:主要在 Windows 10、4GB 内存环境下搭建平台,采用

python 语言编制程序；

2、界面设计：通过 PyQt5 设计平台界面，将各个模块所需图标整齐有序地呈现在界面上；

3、代码编写：使用 python 语言对界面上的 UI 元素进行定义，同时融入本文使用的算法程序，保证平台上的每一个元素能够实现相应功能；

4、测试和打包：设计完成后，运行该平台的 python 程序能够进行功能测试，测试通过后，可以将整个程序打包为一个应用程序软件（.exe），这样可以实现该软件的迁移，方便不同用户的使用。

实际应用过程中，利用高倍摄像机对目标圆形机夹式车刀进行图像采集，并将采集到的图像保存至本地后导入检测平台，或者直接通过平台调用摄像机进行实时拍摄。随后，调用刀具缺陷分类算法和分割算法对图像进行识别与预测，即可获得平台对刀具是否合格的判断结果以及刀具缺陷的分割图像。




图 5-1 平台架构图

Fig. 5-1 Platform architecture diagram

5.3 平台实现及操作

5.3.1 登录与注册界面

登录界面的主要作用是进行用户的身份验证以及保护软件的安全。在打开本文的刀具缺陷识别软件后，首先进入的是如图 5-2 所示的登录界面与注册界面。新用户需要进行注册后才能登录使用该软件其他功能。




图 5-2 登录与注册界面

(a) 登录界面；(b) 注册界面

Fig. 5-2 Login and registration interface (a) Login interface; (b) Registration interface

5.3.2 模型训练界面

通过登录界面后，将进入模型训练界面，如图 5-3 所示。该界面主要展示几种基于 ImageNet 数据集的预训练模型对本文中圆形机夹式车刀刀刃缺陷数据集进行训练后的运行过程和结果，预训练模型包括 VGG-16、VGG-19、Xception、InceptionV3 以及 ResNet50。通过这个界面，可以轻松对比本文使用的 Xception 网络与其它相关网络在训练圆形机夹式车刀图像后的表现情况，同时可以对比不同参数下的训练结果。



图 5-3 模型训练界面

Fig. 5-3 Model training interface

模型训练界面操作步骤如下：

第一步，点击“选择图库”按钮进入本地文件夹，将保存有作好标签分类的圆形机夹式车刀刀刃缺陷图像数据集的文件夹导入软件中，如图 5-4 所示；

第二步，在参数调整区域选择合适的“预训练模型”、“优化算法”，合理调整“迭代次数”、“训练笔数”以及“学习率”，调整好后点击“预训练模型训练”按钮，平台就能够根据用户选择的数据集、预训练模型以及相关参数进行训练，同时在“运行过程”显示区域也可观察到模型训练的运行过程；

第三步，模型训练完成后，点击“显示结果图”按钮即可在图像显示区域观察到准确率、损失率随迭代次数的变化情况以及混淆矩阵的分布情况。通过“结果图保存”，用户可以根据需要将上述三种结果图保存到本地文件夹中。同样，如果用户需要用此次训练权重进行图像预测，可以点击“模型架构保存”按钮和“模型权重保存”按钮分别保存模型训练的架构和权重到本地文件。模型训练后的结果如图 5-5 所示。

最后，若训练过程中发现参数调节不当或其他问题，可点击“停止训练”按钮，即可停止模型训练运行过程。若需要重新开始训练，可点击“清除界面”按钮，即可还原图像显示区域以及运行过程显示区域。完成训练并保存模型架构和权重，点击“识别图片”按钮后，可以进入图像识别界面。



图 5-4 图像导入

Fig. 5-4 Image import




图 5-5 模型训练结果

Fig. 5-5 Model training results

5.3.3 图像检测界面

预训练模型训练展示完成后，将进入图像检测界面，如图 5-6 所示。该界面的主要功能是调用训练好的模型权重和架构对圆形机夹式车刀图像进行识别检测，将其分类为合格或不合格，并且分割刀刃上的剥落缺陷。该界面主要调用前两章中的刀具二分类检测算法以及多任务学习的刀具缺陷分割算法进行分类与分割。需要注意的是，在进行分类以及分割之前，必须在模型训练界面中“选择图库”处导入本文所用的圆形机夹式车刀刃缺陷图像数据集。



图 5-6 图像检测界面

Fig. 5-6 Image detection interface

图像检测界面的操作步骤如下：

第一步，通过“本地图片”按钮可导入本地文件夹中保存的圆形机夹式车刀完整图像，也可通过“打开摄像头”按钮，使用高倍相机对完整刀具进行实时拍摄，调整好焦距后，在图像显示区域观察到刀具刀刃并清晰稳定显示；



图 5-7 分类检测

Fig. 5-7 Classification detection



图 5-8 分割检测

Fig. 5-8 Segmentation detection

第二步,如图 5-7 所示,进行分类检测时,通过“模型架构”、“模型权重”按钮从本地调用本文研究的基于改进 Xception 的刀具二分类检测算法,之后点击“本地分类”按钮对导入的本地刀具图像进行分类,或点击“实时分类”按钮对高倍相机拍摄的刀具图像进行分类。分类后得到的图像上会显示“Qualified”(合格)或“Unqualified”(不合格)的文本及其概率。通过“保存结果”,用户可根据需求将分类后的图像结果保存至本地。

第三步,如图 5-8 所示,进行分割检测时,通过“模型架构”、“模型权重”按钮从本地调用基于多任务学习的 Multi-UF-Xception 刀具缺陷分割算法,用户可通过点击“本地分类”或“实时分类”按钮,分别对导入的本地刀具图像或高倍相机实时拍摄的图像执行分割操作,分割后的图像显示的是刀刃缺陷的 mask 图像。通过“保存结果”,用户可根据需求将分割后的图像结果保存至本地。

最后,如若需要返回模型训练界面,可点击“上一頁”按钮;若需要重新开始识别以及关闭摄像头,可点击“关闭”按钮,即可还原图像显示区域。

5.4 本章小结

本章基于生产实践中对刀具缺陷检测的实际需求,利用 Python 语言的 PyQt5 框架成功构建了一个刀具缺陷检测平台。该平台能够迁移常用的预训练模型,对刀具缺陷数据集进行训练,并直观展示训练过程与结果。同时,通过集成第三章和第四章中提出的刀具缺陷分类与分割算法,平台实现了对刀具的高效分类以及刀刃剥落缺陷的精准分割,为刀具质量检测提供了有力支持。

6. 总结与展望

6.1 研究总结

针对圆形机夹式车刀刀刃缺陷精确检测的难题，本文通过机器学习技术，构建了智能化的圆形机夹式车刀缺陷检测模型，分别提出了有关分类与分割两种缺陷检测方法。在此基础上，还搭建了一个刀具缺陷检测系统平台，实现了对刀具缺陷的智能化检测。通过本文研究可有效保证加工生产质量和精度，及时避免因缺陷导致的经济损失。主要研究结论如下：

(1) 针对圆形机夹式车刀是否合格的问题，提出了一种基于改进 Xception 模型的刀具整体二分类缺陷检测算法。该算法在预训练模型 Xception 网络的基础上，将低层次与深层次的特征进行融合，同时在融合之前加入 CBAM 注意力模块，增强模型的特征提取能力。在使用改进模型进行训练之前，使用图像增强、二值化处理、连通域处理以及形态学处理等图像处理方法将圆形机夹式车刀的刀刃轮廓边缘分离出来作为模型输入，减少刀具表面噪声的干扰，进一步提升模型对刀刃缺陷特征的提取能力。实验结果表明，与原模型以及原输入相比，进行刀刃轮廓提取处理并使用改进模型对圆形机夹式车刀进行分类检测的效果更好，准确率得到明显提升。

(2) 为了进一步研究圆形机夹式车刀的刀刃缺陷检测方法，进行了缺陷分割研究。由于单任务模型无法对刀刃上的小型缺陷特征进行分割处理，所以本文根据分割与分类的关联性，并针对常用圆形车刀刀刃上存在最多的剥落缺陷，提出了一种基于多任务学习的刀刃缺陷分割方法。该方法是在 U-Net 网络模型的基础上，使用 Xception 模型的特征提取网络替换原模型编码器部分，使分类与分割任务共享该特征提取网络，形成多任务学习模型，然后分别对两任务分支进行改进，分割任务融入 FPN 架构以及 AGs 模块，分类任务引入 CBAM 模块并进行多层次特征融合，最后得到多任务学习模型 Multi-UF-Xception。实验结果表明，相对未进行改进的简单多任务学习模型以及单任务分割模型，使用 Multi-UF-Xception 模型对刀刃剥落缺陷进行分割的精度更高，并且在训练过程中进行损失权重调整后，分割精度能够进一步提升。

根据生产实践中的一般需求，搭建了刀具缺陷检测平台。该平台能够根据用户需求进行参数调整，并支持相应的模型训练；同时，平台集成了上述两种算法，能够实现对圆形机夹式车刀合格与不合格的分类，并针对不合格刀具完成刀刃缺陷的分割与提取。通过这些功能，平台不仅实现了生产过程中所需的刀具缺陷智能化检测，还显著提升了检测效率和准确性，有效降低了人工目测带来的主观误差和成本消耗

6.2 研究展望

根据本文展开的研究工作以及研究结果,关于圆形机夹式车刀刀刃缺陷的检测研究仍然有改进空间,以下是可以考虑的几个研究方向:

(1) 进一步优化现有的多任务学习框架,使分类与分割任务之间更好地协同工作,引入细粒度分类技术,提高对不同类型缺陷的识别精度,区分更具体的缺陷类型。

(2) 探索小样本目标检测方法在刀刃缺陷检测中的应用,可以通过生成对抗网络进行数据增强,也可以研究原型网络、匹配网络等少样本学习算法。

(3) 利用 Transformer 模型或者新型模型 Mamba 强大的全局信息捕捉能力,改善复杂背景下 CNN 网络模型的特征提取效果,进而提升模型的泛化能力以及对刀具缺陷的检测精度。

设计更加直观、易用的人机交互界面,方便用户使用刀具缺陷检测平台,建立反馈机制,在操作过程中提供即时反馈,帮助用户了解平台当前状态。

参考文献

- [1] Wang T, Chen Y, Qiao M, et al. A fast and robust convolutional neural network-based defect detection model in product quality control[J]. The International Journal of Advanced Manufacturing Technology, 2018, 94: 3465-3471.
- [2] Liao Z, Abdelhafeez A, Li H, et al. State-of-the-art of surface integrity in machining of metal matrix composites[J]. International journal of machine tools and manufacture, 2019, 143: 63-91.
- [3] Kim D H, Kim T J Y, Wang X, et al. Smart machining process using machine learning: A review and perspective on machining industry[J]. International Journal of Precision Engineering and Manufacturing-Green Technology, 2018, 5: 555-568.
- [4] Bulnes F G, Usamentiaga R, Garcia D F, et al. An efficient method for defect detection during the manufacturing of web materials[J]. Journal of Intelligent Manufacturing, 2016, 27: 431-445.
- [5] Song K, Yan Y. A noise robust method based on completed local binary patterns for hot-rolled steel strip surface defects[J]. Applied Surface Science, 2013, 285: 858-864.
- [6] Zhang H, Shen X, Bo A, et al. A multiscale evaluation of the surface integrity in boring trepanning association deep hole drilling[J]. International Journal of Machine Tools and Manufacture, 2017, 123: 48-56.
- [7] Rao X, Zhang F, Lu Y, et al. Surface and subsurface damage of reaction-bonded silicon carbide induced by electrical discharge diamond grinding[J]. International Journal of Machine Tools and Manufacture, 2020, 154: 103564.
- [8] 潘盛湖, 彭论文, 吕彭杰. 基于改进阈值分割算法的刀具损伤检测方法[J]. 组合机床与自动化加工技术, 2024, (09): 142-146+152.
- [9] 陈泉达, 刘子豪, 金友振, 等. 精密刀具表面缺陷认知神经网络模型研究[J/OL]. 光子·激光, 2025, 1-19.
- [10] Mital A, Govindaraju M, Subramani B. A comparison between manual and hybrid methods in parts inspection[J]. Integrated Manufacturing Systems, 1998, 9(6): 344-349.
- [11] Malamas E N, Petrakis E G M, Zervakis M, et al. A survey on industrial vision systems, applications and tools[J]. Image and vision computing, 2003, 21(2): 171-188.
- [12] Kopardekar P, Mital A, Anand S. Manual, Hybrid and Automated Inspection Literature and Current Research[J]. Integrated Manufacturing Systems, 1993, 4(1): 18-29.
- [13] Fernández-Robles L, Azzopardi G, Alegre E, et al. Machine-vision-based identification of broken inserts in edge profile milling heads[J]. Robotics and Computer-Integrated Manufacturing, 2017, 44: 276-283.
- [14] Zhou P, Zhang C, Xu K, et al. Defect detection of aluminium plates based on near-field enhancement of lamb waves generated using an electromagnetic acoustic transducer[J]. Sensors, 2019, 19(16): 3529.
- [15] Rose J L, Philtron J, Liu G, et al. A hybrid ultrasonic guided wave-fiber optic system for flaw detection in pipe[J]. Applied Sciences, 2018, 8(5): 727.
- [16] Janiesch C, Zschech P, Heinrich K. Machine learning and deep learning[J]. Electronic markets, 2021, 31(3): 685-695.
- [17] Golnabi H, Asadpour A. Design and application of industrial machine vision systems[J].

- Robotics and Computer-Integrated Manufacturing, 2007, 23(6): 630-637.
- [18] Antonelli S, Avola D, Cinque L, et al. Few-shot object detection: A survey[J]. ACM computing surveys (CSUR), 2022, 54(11s): 1-37.
- [19] Fan Q, Zhuo W, Tang C K, et al. Few-shot object detection with attention-RPN and multi-relation detector[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 4013-4022.
- [20] Köhler M, Eisenbach M, Gross H M. Few-shot object detection: A comprehensive survey[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023.
- [21] 丁玉辉, 曹岩, 付雷杰, 等. 刀具磨损检测中的图像处理技术研究现状及展望[J]. 制造技术与机床, 2020, (04): 56-62.
- [22] Guan S. Strip steel defect detection based on saliency map construction using Gaussian pyramid decomposition[J]. ISIJ International, 2015, 55(9): 1950-1955.
- [23] 舒文娉, 刘全香. 基于支持向量机的印品缺陷分类方法[J]. 包装工程, 2014, 35(23):138-142.
- [24] Tao X, Xu D, Zhang Z T, et al. Weak scratch detection and defect classification methods for a large-aperture optical element[J]. Optics Communications, 2017, 387: 390-400.
- [25] 彭道刚, 尹磊, 戚尔江, 等. 基于 OTSU 和区域生长的电厂管道缺陷检测与分割[J]. 红外技术, 2021, 43(5): 502-509.
- [26] 周显恩, 王耀南, 朱青, 等. 基于机器视觉的瓶口缺陷检测方法研究[J]. 电子测量与仪器学报, 2016, 30(05): 702-713.
- [27] Song K, Yan Y. A noise robust method based on completed local binary patterns for hot-rolled steel strip surface defects[J]. Applied Surface Science, 2013, 285: 858-864.
- [28] Shumin D, Zhoufeng L, Chunlei L. AdaBoost learning for fabric defect detection based on HOG and SVM[C]. 2011 International conference on multimedia technology. IEEE, 2011: 2903-2906.
- [29] Tsai D M, Molina D E R. Morphology-based defect detection in machined surfaces with circular tool-mark patterns[J]. Measurement, 2019, 134: 209-217.
- [30] Xia Y, Che T, Meng J, et al. Detection of surface defects for maize seeds based on YOLOv5[J]. Journal of Stored Products Research, 2024, 105: 102242.
- [31] Zhang Y, Yang Q. A survey on multi-task learning[J]. IEEE transactions on knowledge and data engineering, 2021, 34(12): 5586-5609.
- [32] Liu S, Deng W. Very deep convolutional neural network based image classification using small training sample size[C]. 2015 3rd IAPR Asian conference on pattern recognition (ACPR), 2015: 730-734.
- [33] Shobha Y. Classification and Diagnosis of Defects in Steel Surfaces Using Deep Convolutional Neural Networks[J]. 2025.
- [34] Imoto K, Nakai T, Ike T, et al. A CNN-based transfer learning method for defect classification in semiconductor manufacturing[J]. IEEE Transactions on Semiconductor Manufacturing, 2019, 32(4): 455-459.
- [35] Neuhauser F M, Bachmann G, Hora P. Surface defect classification and detection on extruded aluminum profiles using convolutional neural networks[J]. International Journal of Material Forming, 2020, 13(4): 591-603.
- [36] Wei R, Bi Y. Research on recognition technology of aluminum profile surface defects based

- on deep learning[J]. Materials, 2019, 12(10): 1681.
- [37] Li S, Wu C, Xiong N. Hybrid architecture based on CNN and transformer for strip steel surface defect classification[J]. Electronics, 2022, 11(8): 1200.
- [38] Ferreira L. Multi-Model Convolutional Neural Network Fusion for Enhanced Metal Surface Defect Detection and Classification[J]. Journal of Computer Science and Software Applications, 2025, 5(1): 24-32.
- [39] 王一, 龚肖杰, 程佳. 基于改进 U-net 的金属工件表面缺陷分割方法[J]. Laser & Optoelectronics Progress, 2023, 60(15): 1524001.
- [40] He Y, Song K, Meng Q, et al. An end-to-end steel surface defect detection approach via fusing multiple hierarchical features[J]. IEEE transactions on instrumentation and measurement, 2019, 69(4): 1493-1504.
- [41] 李原, 李燕君, 刘进超, 等. 基于改进 Res-UNet 网络的钢铁表面缺陷图像分割研究[J]. 电子与信息学报, 2022, 44(5): 1513-1520.
- [42] Liu L J, Zhang Y, Karimi H R. Defect detection of Printed circuit board Surface based on an improved YOLOv8 with FasterNet backbone algorithms[J]. Signal, Image and Video Processing, 2025, 19(1): 1-9.
- [43] 朱德平, 程光, 姚景丽. 改进 YOLOv5 的汽车齿轮配件表面缺陷检测[J/OL]. 计算机工程与应用, 1-9.
- [44] 窦智, 胡晨光, 李庆华, 等. 改进 YOLOv7 的小样本钢板表面缺陷检测算法[J]. 计算机工程与应用, 2023, 59(23): 283-292.
- [45] Chen R, Cai D, Hu X, et al. Defect detection method of aluminum profile surface using deep self-attention mechanism under hybrid noise conditions[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-9.
- [46] Wang Y, Wei Y S, Wu Z Z, et al. Adaptive convolutional neural network for aluminum surface defect detection[J]. Computational Materials Science, 2023, 227: 112262.
- [47] Liu T, He Z, Lin Z, et al. An adaptive image segmentation network for surface defect detection[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022.
- [48] Wang H, Li M, Wan Z. Rail surface defect detection based on improved Mask R-CNN[J]. Computers and Electrical Engineering, 2022, 102: 108269.
- [49] Liu R, Huang M, Gao Z, et al. MSC-DNet: An efficient detector with multi-scale context for defect detection on strip steel surface[J]. Measurement, 2023, 209: 112467.
- [50] Wang B, Zhao W, Gao P, et al. Crack damage detection method via multiple visual features and efficient multi-task learning model[J]. Sensors, 2018, 18(6): 1796.
- [51] Gibert X, Patel V M, Chellappa R. Deep multitask learning for railway track inspection[J]. IEEE transactions on intelligent transportation systems, 2016, 18(1): 153-164.
- [52] Ho C C, Liu C H, Chen M F, et al. Multi-task Learning Based on Deep Convolutional Neural Networks for Surface Defect Detection of Metal Gaskets[C]. 19th IMEKO TC10 Conference" Measurement for Diagnostics, Optimisation and Control to Support Sustainability and Resilience, 2023.
- [53] Zhang C, Yang H, Ma J, et al. An Efficient End-to-End Multitask Network Architecture for Defect Inspection[J]. Sensors, 2022, 22(24): 9845.
- [54] Meng S, Kuang S, Ma Z, et al. MtlrNet: An effective deep multitask learning architecture for rail crack detection[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-

10.

- [55] Sampath V, Murtua I, Martín J J A, et al. Attention-guided multitask learning for surface defect identification[J]. IEEE Transactions on Industrial Informatics, 2023, 19(9): 9713-9721.
- [56] Kang G, Gao S, Yu L, et al. Deep architecture for high-speed railway insulator surface defect detection: Denoising autoencoder with multitask learning[J]. IEEE Transactions on Instrumentation and Measurement, 2018, 68(8): 2679-2690.
- [57] Dong X, Taylor C J, Cootes T F. Defect classification and detection using a multitask deep one-class CNN[J]. IEEE Transactions on Automation Science and Engineering, 2021, 19(3): 1719-1730.
- [58] 陈希, 宋育斌, 孔维宾, 等. 基于深度学习的刀具磨损检测研究综述[J]. Operations Research and Fuzziology, 2023, 13: 1186.
- [59] 刘浩, 陈再良, 张良. 基于机器学习的刀具表面缺陷检测及分类方法[J]. 计算机测量与控制, 2021, 29(06): 64-68.
- [60] Patange A D, Jegadeeshwaran R. A machine learning approach for vibration-based multipoint tool insert health prediction on vertical machining centre (VMC)[J]. Measurement, 2021, 173: 108649.
- [61] Zhang T, Zhang C, Wang Y, et al. A vision-based fusion method for defect detection of milling cutter spiral cutting edge[J]. Measurement, 2021, 177: 109248.
- [62] 刘浩, 陈再良, 王善翔. 基于改进 YOLOv3 算法的刀具表面缺陷检测[J]. 组合机床与自动化加工技术, 2021, (11): 87-90.
- [63] Shi T, Ding Y, Zhu K, et al. DFP-YOLO: a lightweight machine tool workpiece defect detection algorithm based on computer vision[J]. The Visual Computer, 2024: 1-13.
- [64] Hazzan K E, Pacella M. Surface defect detection and prediction in carbide cutting tools treated by lasers[J]. Procedia CIRP, 2022, 108: 851-856.
- [65] Maini R, Aggarwal H. A comprehensive review of image enhancement techniques[J]. arxiv preprint arxiv:1003.4053, 2010.
- [66] Khan M F, Khan E, Abbasi Z A. Image contrast enhancement using normalized histogram equalization[J]. Optik, 2015, 126(24): 4868-4875.
- [67] Kong N S P, Ibrahim H, Hoo S C. A literature review on histogram equalization and its variations for digital image enhancement[J]. International Journal of Innovation, Management and Technology, 2013, 4(4): 386.
- [68] Shi Z, Feng Y, Zhao M, et al. Normalised gamma transformation - based contrast - limited adaptive histogram equalisation with colour correction for sand - dust image enhancement[J]. IET Image Processing, 2020, 14(4): 747-756.
- [69] Chaki N, Shaikh S H, Saeed K, et al. A comprehensive survey on image binarization techniques[J]. Exploring Image Binarization Techniques, 2014: 5-15.
- [70] Goh T Y, Basah S N, Yazid H, et al. Performance analysis of image thresholding: Otsu technique[J]. Measurement, 2018, 114: 298-307.
- [71] Goyal M. Morphological image processing[J]. IJCST, 2011, 2(4): 59.
- [72] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [73] Lobry S, Marcos D, Murray J, et al. RSVQA: Visual Question Answering for Remote Sensing Data[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(12): 8555-8566.

- [74] 张焕, 张庆, 于纪言. 激活函数的发展综述及其性质分析[J]. 西华大学学报 (自然科学版), 2021, 40(04): 1-10.
- [75] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arxiv preprint arxiv:1704.04861, 2017.
- [76] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 4510-4520.
- [77] Howard A, Sandler M, Chu G, et al. Searching for mobilenetv3[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019: 1314-1324.
- [78] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 1251-1258.
- [79] Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking the inception architecture for computer vision[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 2818-2826.
- [80] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 770-778.
- [81] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]. Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, 2015: 234-241.
- [82] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arxiv preprint arxiv:1409.0473, 2014.
- [83] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 7132-7141.
- [84] Ruder S. An overview of multi-task learning in deep neural networks[J]. arxiv preprint arxiv:1706.05098, 2017.
- [85] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision (ECCV), 2018: 3-19.
- [86] 张欢, 仇大伟, 冯毅博, 等. U-Net 模型改进及其在医学图像分割上的研究综述[J]. 激光与光电子学进展, 2022, 59(02): 1-17.
- [87] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 2117-2125.
- [88] Sun H, Yang S, Chen L, et al. Brain tumor image segmentation based on improved FPN[J]. BMC medical imaging, 2023, 23(1): 172.
- [89] Oktay O, Schlemper J, Folgoc L L, et al. Attention u-net: Learning where to look for the pancreas[J]. arxiv preprint arxiv:1804.03999, 2018.
- [90] Zhou Y, Chen H, Li Y, et al. Multi-task learning for segmentation and classification of tumors in 3D automated breast ultrasound images[J]. Medical image analysis, 2021, 70: 101918.
- [91] He X, Wang Y, Zhao S, et al. Joint segmentation and classification of skin lesions via a multi-task learning convolutional neural network[J]. Expert Systems with Applications, 2023, 230: 120174.
- [92] Kendall A, Gal Y, Cipolla R. Multi-task learning using uncertainty to weigh losses for scene geometry and semantics[C]. Proceedings of the IEEE conference on computer vision and

pattern recognition, 2018: 7482-7491.

- [93] 张陶. 基于学习率衰减的深度学习超参数优化方法的研究[D]. 华中师范大学, 2020.
- [94] 李润泽, 钱仕德, 逯汉宁. 基于机器视觉的汽车装配协作机器人机械故障图像识别系统[J]. 机械制造与自动化, 2023, 52(03):189-192+248.